Università di Pisa

Calcolo Numerico

Anno Accademico 2025–2026

Pietro Bacigalupi

31 marzo 2026

Indice

1 Teoria degli Errori **3**

1.1 Rappresentazione in Virgola Mobile . . . 3

1.2 Teorema di Rappresentazione . . . 3

1.3 Numeri di Macchina . . . 4

1.4 Arrotondamento nelle macchine . . . 5

1.5 Errore nel calcolo di funzione . . . 6

1.5.1 Analisi dell'Errore nel Calcolo di Funzioni . . . 7

1.6 Funzioni Razionali . . . 9

1.6.1 Problemi ben/mal condizionati (come stimare ϵ_d) . . . 10

1.6.2 Errori inerenti delle operazioni aritmetiche di base . . . 12

1.7 Stimare l'errore algoritmico: . . . 13

1.8 Problema Diretto . . . 15

1.9 Funzioni Non Razionali . . . 17

2 Richiami di Algebra Lineare **20**

3 Autovalori e Autovettori **28**

3.1 Autospazi e Molteplicità Geometrica . . . 29

4 Similitudine tra Matrici **29**

5 Diagonalizzabilità **31**

6 Il Teorema Spettrale **33**

7 Proprietà di Autovalori e Autovettori **34**

7.1 Equivalenza tra Norme . . . 37

8 Norme Matriciali **38**

8.1 Norme Indotte (o Naturali) . . . 39

8.2 Esempio di Norma non Indotta: La Norma di Frobenius . . . 40

8.3 Compatibilità tra Norme . . . 40

8.4 Relazioni tra $\|A\|$ e Autovalori di A . . . 41

8.5 Teorema di Hirsch . . . 42

8.6 Interpretazione Geometrica e Convergenza . . . 43

9 Teoremi di Gershgorin **44**

9.1 Definizione e Cerchi di Gershgorin . . . 44

9.2 1° Teorema di Gershgorin . . . 45

9.3 Predominanza Diagonale Forte e Invertibilità . . . 46

9.4 2° Teorema di Gershgorin 46
9.5 Implementazione in MATLAB 47

10 Localizzazione degli Autovalori: 1° Teorema di Gershgorin 48
10.1 Ripasso del 1° Teorema di Gershgorin 48
10.2 Applicazione alla Matrice Trasposta 48

11 2° Teorema di Gershgorin 49

12 Grafi e Matrici 49
12.1 Grafo Associato a una Matrice 49
12.2 Connessione e Riducibilità 49

13 Estensioni ai Teoremi di Gershgorin 50
13.1 3° Teorema di Gershgorin (per matrici irriducibili) 50
13.2 Matrici a Predominanza Diagonale Debole 50

14 Matrici a Blocchi 51
14.1 Matrici Triangolari e Diagonali a Blocchi 51

15 Risoluzione di Sistemi Lineari con Matrici Riducibili 52
15.1 Vantaggio Computazionale 52

16 Grafi e Matrici Riducibili (Continua) 53

17 Sistemi Lineari: Metodi Risolutivi 55
17.1 Sistemi Triangolari 55
17.2 Metodo di Eliminazione di Gauss (MEG) 56

18 Fattorizzazione LU 56
18.1 Risoluzione di Sistemi Multipli e Calcolo dell'Inversa 57

19 Il Metodo di Gauss con Pivoting Parziale 58
19.1 Effetti del Pivoting sulla Fattorizzazione LU 59

20 Calcolo del Determinante tramite LU 59

21 Condizionamento di un Sistema Lineare 60

1 Teoria degli Errori

1.1 Rappresentazione in Virgola Mobile

Fissata una base $\beta > 1$, con $\beta \in \mathbb{N}$, un numero reale x può essere rappresentato nella forma:

$$x = \text{segno}(x) \cdot \beta^e \cdot \sum_{i=1}^{\infty} \alpha_i \, \beta^{-i} \tag{1}$$

dove:

- β è la base della rappresentazione;
- $e \in \mathbb{Z}$ è l'esponente;
- α_i sono le cifre della mantissa, tali che

$$0 \leq \alpha_i \leq \beta - 1 \tag{2}$$

e

$$\text{segno}(x) = \begin{cases} +1 & \text{se } x > 0 \\ -1 & \text{se } x < 0 \end{cases}$$

Attenzione

La rappresentazione così non è unica, ad esempio: $3{,}14 = 0{,}0314 \cdot 10^2$.

1.2 Teorema di Rappresentazione

Data $\beta > 1 \in \mathbb{N}$, $x \in \mathbb{R} \neq 0$ allora $\exists!$ rappresentazione di x in base β :

1. $\alpha_1 \neq 0$
2. $\nexists K \in \mathbb{N} : \alpha_j = \beta - 1 \forall j > k$

L'unica rappresentazione che verifica il teorema si dice **Rappresentazione in virgola mobile normalizzata**. Dove $\sum_{i=1}^{\infty} \alpha_i \, \beta^{-i}$ si dice **Mantissa** di $x \in \mathbb{R}$ e vale sempre che $\beta^{-1} < \sum_{i=1}^{\infty} \alpha_i \, \beta^{-i} < 1$

Esempio

La (1) esclude rappresentazioni con primo numero decimale uguale a 0:

- $0,\mathbf{0}123 \cdot 10^3$ Non va bene
- $1230,\mathbf{0} \cdot 10^0$ Non va bene
- $0,123 \cdot 10^5$ Va bene

La (2) esclude numeri in periodici con 9 finali (Esempio $1,4\overline{9}$, in base 10)

1.3 Numeri di Macchina

Problema : abbiamo inf cifre, ne possiamo tenere in considerazione solo un numero finito. Come facciamo? Tronchiamo la mantissa e limitiamo l'esponente.

Definizione : Dati, β, m, L, U, $\beta > 1$, $L \leq u$ e $m > 0$ definiamo **Insieme dei numeri di macchina** la funzione

$$F(\beta, m, L, U) = \left\{ x \in \mathbb{R} \;\middle|\; x = \text{segno}(x)\, \beta^e \sum_{i=1}^{m} \alpha_i \beta^{-i},\ L \leq e \leq U,\ \alpha_i \in \{0, 1, \ldots, \beta - 1\},\ \alpha_1 \neq 0 \right\} \cup \{0\}$$

I numeri di macchina sono un sottoinsieme dei numeri reali esattamente rappresentabili da un software

Esempio $\beta = 2$ $m = 3$ $L = -1$ $U = 3$ Ci sono un numero costante di elementi in $[\beta^{e-1}, \beta^e)$ e sono equispaziati.
Stiamo studiando quindi i **numeri macchina di base 2 con 3 cifre di mantissa** ed esponente da -1 a 3
Sono equispaziati in **scala logaritmica** negli intervalli

$$\left[2^i, 2^{i+1}\right)$$

quindi:

1. $[2^{-1}, 2^0) = [1/2, 1]$
2. $[2^0, 2^1) = [1, 2]$
3. $[2^1, 2^2) = [2, 4]$
4. $[2^2, 2^3) = [4, 8]$

Osservazione

Minimo Rappresentabile:

$$\beta^{\mathbf{L}} \cdot \alpha_{\mathbf{1}} \cdot \beta^{-\mathbf{1}} = \beta^{\mathbf{L-1}} \text{ dato che } \alpha_1 = 1$$

Massimo Rappresentabile:

$$\beta^U \cdot (\beta - 1) \sum_{j=1}^{m} \beta^{-j} = \beta^U \cdot (\beta - 1) \left(\frac{1 - \beta^{-m-1}}{1 - \beta^{-1}} - 1 \right) = \beta^U \left(1 - \beta^{-m} \right)$$

Quanti sono i numeri macchina rappresentabili:

$$\underbrace{2}_{\text{segno}} \quad \underbrace{(U - L + 1)}_{\text{esponente}} \quad \underbrace{\left(\beta^m - \beta^{m-1}\right)}_{\text{mantissa}} \quad \underbrace{+1}_{\{0\}}$$

1.4 Arrotondamento nelle macchine

Formato	β	m	L	U	Byte	$\varepsilon(precisione)$	$\lvert F \rvert$
Double	2	53	-1021	1024	8	2^{-52}	$2(2046)(2^{53} - 2^{52}) + 1$
Single	2	24	-124	128	4	2^{-23}	$2(253)(2^{24} - 2^{23}) + 1$

Tabella 1: Parametri IEEE 754 in virgola mobile

Osservazione Dato $x \in \mathbb{R}$, in generale $x \notin F(\beta, m, L, U)$. Si distinguono tre casi:

1. Se $|x| > \beta^U(1 - \beta^{-m})$ si ha **overflow**.
2. Se $0 < |x| < \beta^{L-1}$ si ha **underflow**.
3. Se
$$\beta^{L-1} \leq |x| \leq \beta^U(1 - \beta^{-m}),$$
il numero è rappresentabile in ordine di grandezza ma può richiedere **arrotondamento**.

Definizione Si definisce **funzione di arrotondamento** una funzione

$$\mathrm{RD} : \mathbb{R} \longrightarrow F(\beta, m, L, U)$$

che ad ogni numero reale x associa un numero macchina $\mathrm{RD}(x)$ appartenente all'insieme $F(\beta, m, L, U)$.

Le scelte più comuni sono:

1. **Troncamento**: $TR(x) = \lfloor x \rfloor \forall x$
2. **Round-UP**: $UP(x) = \lceil x \rceil \forall x$
3. **Round-To-Nearest**:

$$\text{RN(x)} = \begin{cases} \lfloor x \rfloor \text{ se } \alpha_{m+1} < \frac{\beta}{2} \\ \lceil x \rceil \text{ se } \alpha_{m+1} \geq \frac{\beta}{2} \end{cases}$$

Quella usata dai calcolatori, che useremo noi, è la **(3)**

Definizione Sia $x \in \mathbb{R}$ e sia $\text{RN}(x)$ il numero macchina ottenuto mediante arrotondamento al più vicino (round-to-nearest).

Si definisce **errore assoluto di arrotondamento** la quantità

$$\delta(x) = x - \text{RN}(x).$$

Si definisce **errore relativo di arrotondamento** la quantità

$$\varepsilon(x) = \frac{\delta(x)}{x}, \qquad x \neq 0.$$

Nel caso di arrotondamento al più vicino vale la stima

$$|\delta(x)| \leq \frac{1}{2}\,\beta^{e-m}.$$

Poiché $|x| \geq \beta^{e-1}$, si ottiene

$$|\varepsilon(x)| = \frac{|\delta(x)|}{|x|} \leq \frac{\frac{1}{2}\beta^{e-m}}{\beta^{e-1}} = \frac{1}{2}\beta^{1-m}.$$

Si osserva che il termine finale non dipende da x.

La quantità

$$u = \frac{1}{2}\beta^{1-m}$$

è detta **precisione di macchina** (o *unit roundoff*). In doppia precisione (IEEE 754):

$$u = 2^{-53} \approx 1.11 \times 10^{-16}.$$

1.5 Errore nel calcolo di funzione

Le operazioni di macchina sono 4 e sono $\otimes \oplus \ominus \oslash$ dove

- $x \oplus y = RN(x + y)$

- $x \ominus y = RN(x - y)$
- $x \otimes y = RN(x \cdot y)$
- $x \oslash y = RN(x \div y)$

Non è valida la proprietà associativa e distributiva

1.5.1 Analisi dell'Errore nel Calcolo di Funzioni

Sia $f : \mathbb{R}^m \to \mathbb{R}$ una funzione matematica che vogliamo valutare. Si vuole calcolare il valore $f(p_0)$, dove il punto di partenza è un vettore di m componenti:

$$p_0 = (x_1^{(0)}, x_2^{(0)}, \dots, x_m^{(0)}) \in \mathbb{R}^m$$

Fonti dell'errore: Nel passaggio dalla teoria alla pratica, incontriamo tre ostacoli principali:

1. **Approssimazione della funzione**: La funzione teorica f viene sostituita da una funzione $\tilde{f}$ che il calcolatore sa gestire (ovvero che usa solo operazioni elementari). *Esempio: calcolare e^x usando solo i primi termini dello sviluppo di Taylor.*
2. **Algoritmizzazione**: La funzione $\tilde{f}$ viene tradotta in un algoritmo $\tilde{f}_a$. Qui entrano in gioco le operazioni di macchina $\oplus, \ominus, \otimes, \oslash$, ognuna delle quali introduce un errore di arrotondamento.
3. **Arrotondamento dei dati**: Il punto p_0 originale spesso non è rappresentabile esattamente in memoria (pensa a π o a numeri con troppe cifre). Viene quindi sostituito dal numero di macchina più vicino: $p_1 = \mathrm{RN}(p_0)$.

Conclusione: Il nostro obiettivo sarebbe ottenere $f(p_0)$, ma ciò che il computer ci restituisce effettivamente è $\tilde{f}_a(p_1)$.

Esempio: Calcolo di e^π Vogliamo calcolare il valore della funzione $f(x) = e^x$ nel punto $p_0 = \pi$.

1. **Approssimazione matematica**: Poiché il calcolatore non può calcolare la funzione esponenziale esatta, usiamo uno sviluppo di Taylor troncato al secondo ordine:

$$f(x) \approx 1 + x + \frac{x^2}{2} =: \tilde{f}(x)$$

2. **Arrotondamento dell'input**: Il numero π ha infinite cifre. Lo arrotondiamo a un numero di macchina p_1 (nell'esempio con 5 cifre):

$$p_1 = RN(\pi) = 3.1415$$

3. **Esecuzione dell'algoritmo**: Implementiamo la formula usando solo operazioni di macchina. L'ordine scelto definisce l'algoritmo $\tilde{f}_a(p_1)$:

$$\tilde{f}_a(p_1) = 1 \oplus (p_1 \oplus ((p_1 \otimes p_1) \oslash 2))$$

Grafo computazionale: L'algoritmo sopra descritto può essere visualizzato tramite il seguente schema di flusso:

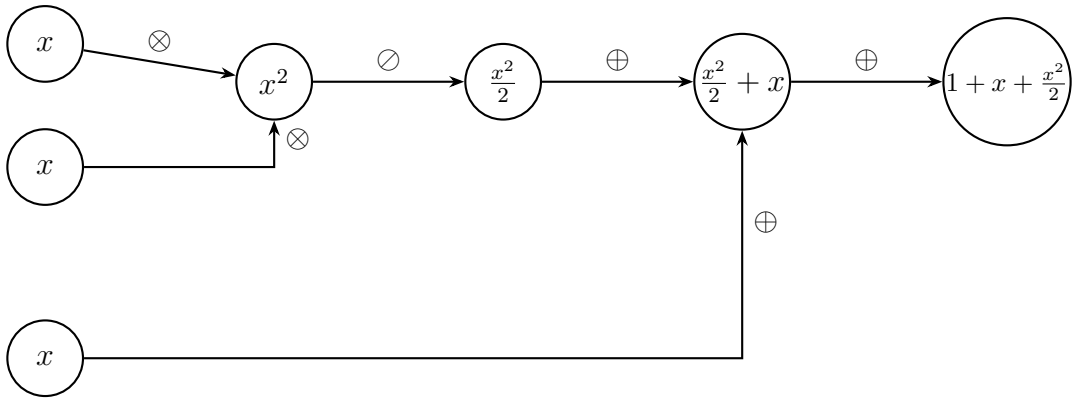

Analisi e Spiegazione del Grafo Computazionale Il grafo sopra riportato rappresenta la struttura logica e sequenziale dell'algoritmo $\tilde{f}_a(p_1)$. In analisi numerica, questo schema è fondamentale per visualizzare come l'errore si genera e si propaga attraverso i calcoli.

- **Nodi di Input (Sorgenti)**: I cerchi a sinistra contenenti x rappresentano il numero di macchina $p_1 = RN(\pi)$. Nel grafo, lo stesso valore x viene "pescato" tre volte dalla memoria per alimentare i diversi rami del calcolo.
- **Nodi Operatori (Cerchi con $\otimes, \oslash, \oplus$)**: Ogni cerchio che contiene un simbolo operativo rappresenta un'operazione di macchina.
  - Il primo nodo esegue $x \otimes x$, producendo il risultato parziale x^2.
  - Il secondo nodo riceve x^2 e lo divide per la costante 2 tramite l'operatore $\oslash$.
  - Il terzo e il quarto nodo eseguono le somme ($\oplus$) necessarie per completare il polinomio di Taylor.

- **Propagazione dell'Errore locale**: Ogni freccia che entra in un operatore porta con sé un valore potenzialmente già viziato da errori precedenti. Ogni nodo operatore, a sua volta, introduce un nuovo **errore di arrotondamento locale** dovuto alla funzione $RN(\cdot)$, poiché il risultato di un'operazione tra numeri di macchina non è necessariamente un numero di macchina.

- **Significato Algoritmico**: Il grafo evidenzia che l'algoritmo non calcola la funzione "tutta insieme", ma come una catena di eventi. L'errore totale δ_f è dunque la somma accumulata degli errori nati in ogni singolo nodo del grafo, influenzata pesantemente dall'ordine in cui le operazioni sono collegate tra loro.

Definizione: Errore Totale

Data $f : \mathbb{R}^m \to \mathbb{R}$, un punto p_0 e un algoritmo $\tilde{f}_a$, l'errore totale è dato da:

$$\delta_f = \tilde{f}_a(p_1) - f(p_0) \quad \text{dove } p_1 = RN(p_0)$$

1.6 Funzioni Razionali

Per semplificare l'analisi, assumiamo che f sia una **funzione razionale**, ovvero definibile mediante un numero finito di operazioni elementari $\{+, -, \times, /\}$. In questo caso, la funzione approssimata coincide con quella teorica: $\tilde{f}(x) = f(x)$.

Errore Assoluto L'errore assoluto totale δ_f può essere scomposto come segue:

$$\begin{aligned}
\delta_f &= f_a(p_1) - f(p_0) \\
&= f_a(p_1) - f(p_1) + f(p_1) - f(p_0) \\
&= \delta_a + \delta_d
\end{aligned}$$

dove:

- $\delta_a = f_a(p_1) - f(p_1)$ è l'**errore algoritmico**;
- $\delta_d = f(p_1) - f(p_0)$ è l'**errore inerente**.

Errore Relativo L'errore relativo ϵ_f si ottiene dividendo l'errore assoluto per il valore esatto:

$$\begin{aligned}
\epsilon_f &= \frac{\delta_f}{f(p_0)} = \frac{f_a(p_1) - f(p_0)}{f(p_0)} \\
&= \frac{\delta_a}{f(p_0)} + \frac{\delta_d}{f(p_0)} \\
&= \frac{f_a(p_1) - f(p_1)}{f(p_1)} \cdot \frac{f(p_1)}{f(p_0)} + \epsilon_d \\
&= \epsilon_a \left(1 + \frac{f(p_1) - f(p_0)}{f(p_0)}\right) + \epsilon_d \\
&= \epsilon_a(1 + \epsilon_d) + \epsilon_d
\end{aligned}$$

Sviluppando il prodotto si ottiene $\epsilon_a + \epsilon_a\epsilon_d + \epsilon_d$. Poiché ϵ_a ed ϵ_d sono quantità molto piccole, il loro prodotto $\epsilon_a\epsilon_d$ è trascurabile (ordine superiore). Pertanto:

$$\epsilon_f \approx \epsilon_a + \epsilon_d \tag{3}$$

In generale, per limitare $|\delta_f|$ si cercano disuguaglianze del tipo:

$$|\delta_a| < \tau_1, \quad |\delta_d| < \tau_2 \implies |\delta_f| < \tau_1 + \tau_2$$

1.6.1 Problemi ben/mal condizionati (come stimare ϵ_d)

Errore assoluto inerente: Definiamo l'errore assoluto inerente come:

$$\delta_d := f(p_1) - f(p_0)$$

Sotto l'ipotesi che $f \in C^1(D), D \subseteq \mathbb{R}^m$ e $p_0 \in D$, si può sfruttare lo **sviluppo di Taylor** di f centrato in p_0 troncato al primo ordine:

$$\begin{aligned}
f(p_1) - f(p_0) &= f(p_0) + \nabla f(\widetilde{p})^T(p_1 - p_0) - f(p_0) \quad \text{dove } \widetilde{p} \in \overline{p_1 p_0} \\
&= \nabla f(\widetilde{p})^T(p_1 - p_0) = \sum_{j=1}^{m} \frac{\partial f}{\partial x_j}(\widetilde{p}) \cdot (x_j^{(1)} - x_j^{(0)}) \\
&\approx \sum_{j=1}^{m} \frac{\partial f}{\partial x_j}(p_0) \cdot (x_j^{(1)} - x_j^{(0)})
\end{aligned}$$

Definendo $\delta_j = (x_j^{(1)} - x_j^{(0)})$ come l'errore sulla componente j-esima di p_0, otteniamo la stima:

$$\delta_d \approx \sum_{j=1}^{m} \frac{\partial f}{\partial x_j}(p_0) \cdot \delta_j$$

Coefficienti di amplificazione: Le derivate parziali $\frac{\partial f}{\partial x_j}(p_0)$ agiscono come **coefficienti di amplificazione** dell'errore.

- Se una derivata è molto grande in modulo, anche un piccolo errore di arrotondamento δ_j nella componente j dell'input può portare a un errore inerente δ_d molto grande nel risultato finale.
- In questo caso, diciamo che il problema è **mal condizionato**.

Errore relativo inerente: L'errore relativo inerente ϵ_d è definito come il rapporto tra l'errore assoluto inerente e il valore esatto della funzione nel punto p_0:

$$\epsilon_d := \frac{f(p_1) - f(p_0)}{f(p_0)} \tag{4}$$

Sostituendo la stima del primo ordine ottenuta con Taylor, possiamo riscrivere l'espressione per evidenziare gli errori relativi sulle singole componenti ϵ_j:

$$\begin{aligned}\epsilon_d \approx \frac{\sum_{j=1}^{m} \frac{\partial f}{\partial x_j}(p_0) \cdot \delta_j}{f(p_0)} &= \sum_{j=1}^{m} \frac{x_j^{(0)}}{f(p_0)} \frac{\partial f}{\partial x_j}(p_0) \cdot \frac{x_j^{(1)} - x_j^{(0)}}{x_j^{(0)}} \\ &= \sum_{j=1}^{m} \underbrace{\left(\frac{x_j^{(0)}}{f(p_0)} \frac{\partial f}{\partial x_j}(p_0) \right)}_{\rho_j} \cdot \epsilon_j\end{aligned}$$

dove $\epsilon_j = \frac{x_j^{(1)} - x_j^{(0)}}{x_j^{(0)}}$ rappresenta l'errore relativo sulla componente j-esima di p_0.

$$\epsilon_d \approx \sum_{j=1}^{m} \epsilon_j \rho_j \quad \text{dove } \rho_j := \frac{x_j^{(0)}}{f(p_0)} \frac{\partial f}{\partial x_j}(p_0)$$

I termini ρ_j sono detti **coefficienti di amplificazione** (o coefficienti di condizionamento relativo).

Condizionamento del problema: In base al modulo dei coefficienti ρ_j, possiamo classificare la stabilità del calcolo della funzione rispetto alle perturbazioni dei dati di input:

- **Problema mal condizionato**: Si verifica quando i coefficienti ρ_j sono grandi in modulo (o ne esiste almeno uno molto grande). In questo caso, anche piccoli errori relativi nei dati ϵ_j vengono fortemente amplificati nel risultato finale.

- **Problema ben condizionato**: Si verifica quando i coefficienti ρ_j sono "piccoli" (tipicamente vicini a 1). In tale situazione, l'errore relativo finale ϵ_d risulta dello stesso ordine di grandezza degli errori sui dati ϵ_i.

1.6.2 Errori inerenti delle operazioni aritmetiche di base

Consideriamo il caso in cui la funzione f rappresenti un'operazione aritmetica elementare tra due variabili ($m = 2$), ovvero $f(x, y) = x$ op y. Nella tabella seguente sono riportati l'errore assoluto inerente δ_d e l'errore relativo inerente ϵ_d per le quattro operazioni di macchina.

Operatore	**Errore inerente** δ_d	**Errore inerente relativo** ϵ_d
$x \oplus y$	$\delta_x + \delta_y$	$\frac{x}{x+y}\epsilon_x + \frac{y}{x+y}\epsilon_y$
$x \ominus y$	$\delta_x - \delta_y$	$\frac{x}{x-y}\epsilon_x - \frac{y}{x-y}\epsilon_y$
$x \otimes y$	$y\delta_x + x\delta_y$	$\epsilon_x + \epsilon_y$
$x \oslash y$	$\frac{1}{y}\delta_x - \frac{x}{y^2}\delta_y$	$\epsilon_x - \epsilon_y$

Tabella 2: Analisi dell'errore inerente per le operazioni elementari ($m = 2$)

Osservazioni sul condizionamento: Dalla tabella si possono trarre conclusioni fondamentali sulla stabilità delle operazioni:

- **Moltiplicazione e Divisione**: Sono operazioni sempre **ben condizionate**, poiché i coefficienti di amplificazione sono unitari ($\rho_x = 1, \rho_y = \pm 1$). L'errore relativo finale è semplicemente la somma o differenza degli errori relativi iniziali.

- **Addizione e Sottrazione**: Il condizionamento dipende dai valori di x e y. In particolare, nella sottrazione $x \ominus y$, se $x \approx y$, il denominatore $(x - y)$ tende a zero, rendendo i coefficienti ρ_j estremamente grandi. Questo fenomeno è noto come **cancellazione numerica** ed è una delle principali cause di mal condizionamento nei calcoli.

1.7 Stimare l'errore algoritmico:

Fissato un algoritmo $f_a(x)$ possiamo stimare $\delta_a = f(p_1) - f_a(p_1), \epsilon_a = \frac{f(p_1)-f_a(p_1)}{f(p_1)}$ (Errore assoluto e relativo algoritmico). Assumiamo che non ci sia errore sui dati iniziali dato che $p_1 \in F(\beta, m, l, U)$ e studiamo come le operazioni di macchina propagano l'errore di arrotondamento sui risultati intermedi.

Esempi pratici:

$$f(x, y, z, w) = x(\frac{y}{z} - w) \quad f_a(x) = x \otimes ((y \oslash z) \ominus w)$$

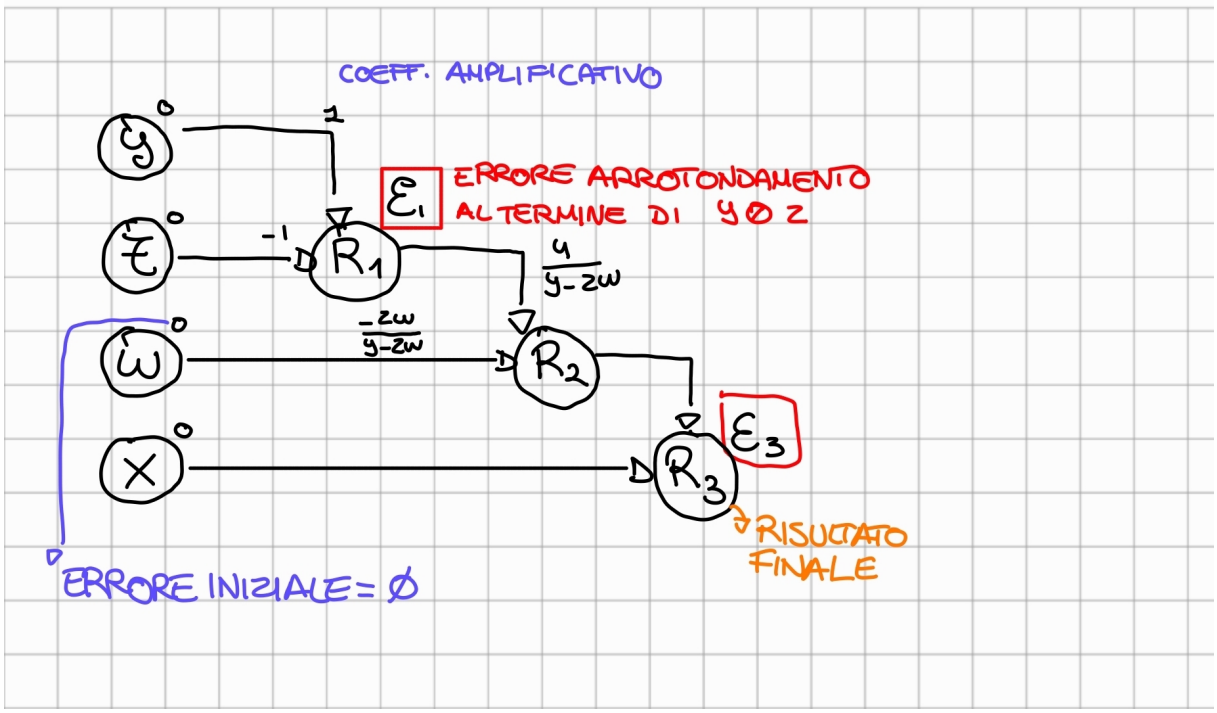

Spiegazione

- Sulla sinistra ci sono i valori iniziali y^0, z^0, w^0, x^0. In questa analisi ci si concentra solo sull'errore introdotto dall'algoritmo, quindi assumiamo che i dati in ingresso siano esatti.
- Il calcolatore esegue la prima operazione: $y \oslash z$.
  - **Risultato intermedio** ($r1$): Rappresenta il valore della divisione memorizzato in memoria
  - **Errore locale** (ε_1): Poichè il risultato di $y \div z$ potrebbe avere infinite cifre, il computer deve arrotondarlo. Questo arrotondamento genera l'errore locale ε_1

- **Coefficienti sui rami**: Sulle frecce che entrano in r_1 i valori 1 e -1 indicano l'errore che si propaga nella divisione.

- Il valore ottenuto (r_1) viene sottratto a w : $(r_1 \ominus w)$.
  - **Risultato intermedio (r_2)**: Adesso è il risultato della parentesi tonda
  - **Errore locale (ε_2)** Operazione di sottrazione introduce un nuovo errore di arrotondamento proprio, indicato con ε_2
  - **Coefficienti di amplificazione**: Se il denominatore $(y - zw)$ è molto piccolo (ovvero se $\frac{y}{z} \approx w$), quesi coefficienti diventano enormi, causando il fenomeno della **cancellazione numerica** (problema mal condizionato).

- Infine, il risultato (r_2) viene moltiplicato per x : $x \otimes r_2$.
  - **Risultato finale (r_3)**: Valore definitivo restituito dal calcolatore.
  - **Errore locale (ε_3)** Anche quest'ultima moltiplicazione introduce un piccolo errore di arrotondamento finale.
  - **Propagazione**: La moltiplicazione per sè non amplifica ulteriormente gli errori precedenti in modo drammatico.

$$
\begin{aligned}
\epsilon_{r_3} &= \epsilon_3 + 1\epsilon_x + 1\epsilon_{r_2} = \epsilon_3 + \epsilon_{r_2} \\
&= \epsilon_3 + \epsilon_2 + \left(\frac{-zw}{y - zw}\right)\epsilon_w + \frac{y}{y - zw}\epsilon_{r_1} = \\
&= \epsilon_3 + \epsilon_2 + \frac{y}{y - zw}\epsilon_{r_1} = \epsilon_3 + \epsilon_2 + \frac{y}{y - zw}(\epsilon_1 + 1\epsilon_y - 1\epsilon_z) = \\
&= \epsilon_3 + \epsilon_2 + \frac{y}{y - zw}\epsilon_1 = \epsilon_a \quad \text{Sapendo che } \epsilon_w, \epsilon_y, \epsilon_x, \epsilon_z = 0
\end{aligned}
$$

Vale che $|\epsilon_1|, |\epsilon_2|, |\epsilon_3| \leq u$.
Nel caso di errori assoluti: $|\delta_1|, |\delta_2|, |\delta_3| \leq u \cdot \max\{|x|, |y|, |z|\}$

Esempio $f(x, y) = x^2 - y^2$

Algoritmo 1:

$r_1 = x \cdot x$

$r_2 = y \cdot y$

$r_3 = r_1 - r_2$

$$\epsilon_a = \epsilon_3 + \frac{x^2}{x^2 - y^2}\epsilon_1 - \frac{y^2}{x^2 - y^2}\epsilon_2$$

Algoritmo 2:

$r_1 = x + y$

$r_2 = x - y$

$r_3 = r_1 \cdot r_2$

$$\epsilon_a = \epsilon_1 + \epsilon_2 + \epsilon_3$$

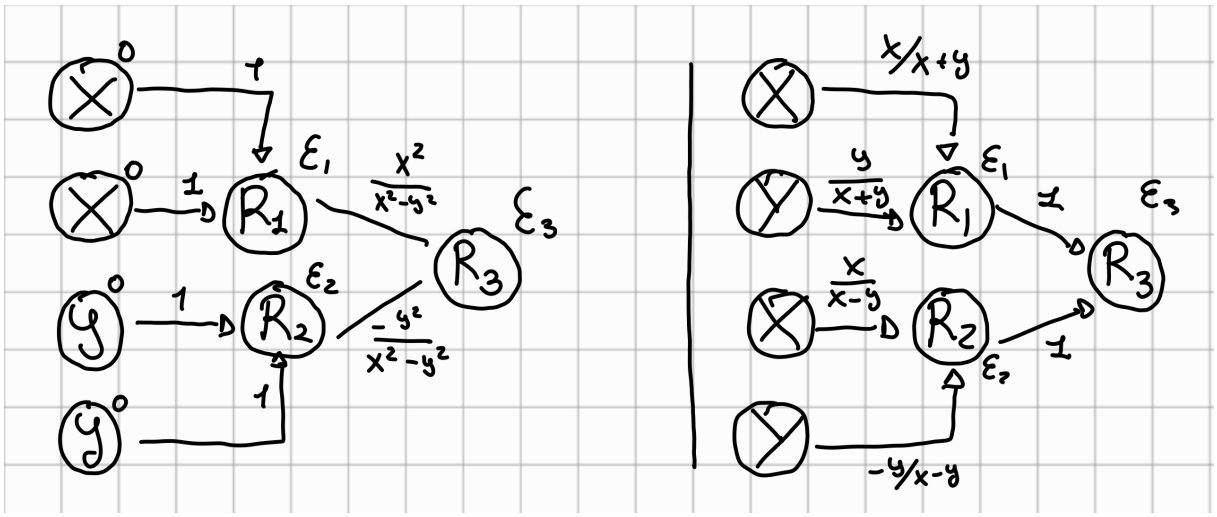

Nota tecnica:
L'**Algoritmo 1** è numericamente instabile quando $x \approx y$ a causa del fenomeno della *cancellazione numerica* (i coefficienti dell'errore ϵ_1 ed ϵ_2 tendono all'infinito).
L'**Algoritmo 2** è invece numericamente stabile poiché l'errore generato ϵ_a è semplicemente la somma degli errori locali di arrotondamento, indipendentemente dai valori di x e y.

1.8 Problema Diretto

Le tecniche viste per stimare ϵ_a e ϵ_d le possiamo usare per stimare

$$|\epsilon_f| \leq |\epsilon_d| + |\epsilon_a|$$
$$|\delta_f| \leq |\delta_d| + |\delta_a|$$

Problema diretto: Date f, una stima degli errori δ_{x_i} e un algoritmo, vogliamo stimare δ_f per $p_0 \in D \subseteq \mathbb{R}^m$

Esempio

Consideriamo la funzione $f(x_1, x_2) = \frac{x_1}{x_2}$ definita in un dominio D tale che $x_1 \in [1, 3]$ e $x_2 \in [4, 5]$ ($D = [1, 3] \times [4, 5], p_0 \in D$). Supponiamo che l'errore sui dati sia limitato da $|\delta_{x_i}| < \frac{1}{2} \cdot 10^{-2}$ per $i = 1, 2$.

Errore inerente: Vogliamo determinare una maggiorazione per l'errore inerente δ_d. Calcoliamo le derivate parziali e i loro estremi superiori nel dominio D:

- Rispetto a x_1:

$$\frac{\partial f}{\partial x_1} = \frac{1}{x_2} \implies A_1 = \sup_{x \in D} \left| \frac{\partial f}{\partial x_1}(x) \right| = \sup_{(x_1,x_2) \in D} \left| \frac{1}{x_2} \right| = \frac{1}{4}$$

- Rispetto a x_2:

$$\frac{\partial f}{\partial x_2} = -\frac{x_1}{x_2^2} \implies A_2 = \sup_{x \in D} \left| \frac{\partial f}{\partial x_2}(x) \right| = \sup_{(x_1,x_2) \in D} \left| -\frac{x_1}{x_2^2} \right| = \frac{3}{16}$$

Dunque, la stima dell'errore totale basata sulla scomposizione $|\delta_f| \leqslant |\delta_a| + |\delta_d|$ diventa:

$$|\delta_f| \leqslant |\delta_a| + A_1|\delta_{x_1}| + A_2|\delta_{x_2}| = |\delta_a| + \frac{1}{4} \cdot \frac{1}{2} \cdot 10^{-2} + \frac{3}{16} \cdot \frac{1}{2} \cdot 10^{-2}$$

Errore algoritmico: L'errore algoritmico può essere stimato usando la linearizzazione:

$$\delta_a = \sum_{j=1}^{m} \frac{\partial f}{\partial x_j}(p_0) \cdot \delta_j \implies |\delta_a| \leqslant \sum_{j=1}^{m} \sup_{p \in D} \left| \frac{\partial f}{\partial x_j}(p) \right| \cdot |\delta_j|$$

In questo caso specifico (divisione di macchina), l'errore algoritmico è dato dall'arrotondamento del risultato:

$$|\delta_a| = \left| \frac{x_1}{x_2} \right| \cdot \frac{1}{2} \cdot 10^{-2} \quad \text{(dato solo dall'errore di troncamento)}$$

Dunque l'errore assoluto: Combinando i risultati ottenuti:

$$|\delta_f| \leqslant \left| \frac{x_1}{x_2} \right| \cdot \frac{1}{2} \cdot 10^{-2} + \frac{1}{4} \cdot \frac{1}{2} \cdot 10^{-2} + \frac{3}{16} \cdot \frac{1}{2} \cdot 10^{-2} = \frac{23}{32} \cdot 10^{-2} \leqslant 1$$

Problema Inverso

Problema inverso: dato $\tau > 0$, f e $p_0 \in \mathbb{R}^m$, determinare un algoritmo e un valore di precisione di macchina u tale per cui:

$$|\delta_f| < \tau$$

Esempio Sia $f(x_1, x_2) = \frac{x_1}{x_2}$ con dominio $D = [1, 2] \times [-2, -1]$. Si vuole trovare un algoritmo e una precisione u per cui $|\delta_f| < 10^{-2}$.

Scegliamo $x_1 \oslash x_2$ come algoritmo e stimiamo gli errori sui dati $|\delta_{x_1}|, |\delta_{x_2}|$:

$$|\delta_{x_i}| \leqslant u \cdot |x_i| \leqslant 2u, \quad i = 1, 2$$

Calcoliamo i coefficienti di amplificazione (derivate parziali):

- $A_1 = \sup_D \left|\frac{\partial f}{\partial x_1}\right| = \sup_D \left|\frac{1}{x_2}\right| = 1$
- $A_2 = \sup_D \left|\frac{\partial f}{\partial x_2}\right| = \sup_D \left|-\frac{x_1}{x_2^2}\right| = 2$

Stima dell'errore totale: Utilizzando la scomposizione dell'errore e le maggiorazioni trovate:

$$\begin{aligned}|\delta_f| &\leqslant |\delta_a| + \underbrace{2u}_{|\delta_{x_1}|\cdot A_1} + \underbrace{2u}_{|\delta_{x_2}|\cdot A_2} \\ &\leqslant \max_D \left|\frac{x_1}{x_2}\right| \cdot u + 4u = 2u + 4u = 6u\end{aligned}$$

Determinazione di u: Per soddisfare la richiesta del problema:

$$|\delta_f| \leqslant 6u \leqslant 10^{-2} \implies u = \frac{1}{6} \cdot 10^{-2}$$

1.9 Funzioni Non Razionali

Se si deve valutare un'espressione matematica **non razionale** (ad esempio $f(x, y) = e^{\cos(x+y)}$), il calcolatore non può calcolarla esattamente. Si procede quindi scegliendo un'approssimazione razionale $\tilde{f}(x) \approx f(x)$ (ad esempio tramite uno sviluppo di Taylor) e si valuta $\tilde{f}(p_0)$.

A causa dell'uso dell'aritmetica floating point e dell'approssimazione della funzione, quello che si ottiene effettivamente è $\tilde{f}_a(p_1)$. Si osserva che l'errore totale può essere scomposto come:

$$f(p_0) - \tilde{f}_a(p_1) = \underbrace{f(p_0) - f(p_1)}_{\delta_d} + \underbrace{f(p_1) - \tilde{f}(p_1)}_{\delta_{an}} + \underbrace{\tilde{f}(p_1) - \tilde{f}_a(p_1)}_{\delta_a}$$

Dove i contributi sono:

- δ_d: **Errore inerente** sulla funzione originale f;
- δ_{an}: **Errore analitico** (dovuto all'approssimazione di f con $\tilde{f}$);
- δ_a: **Errore algoritmico** sulla funzione approssimata $\tilde{f}$.

$$\delta_f = \delta_d + \delta_a + \delta_{an}$$

Osservazione: L'errore inerente è calcolato sulla funzione originale (f), mentre l'errore algoritmico è calcolato sulla funzione approssimata $\tilde{f}$ (di conseguenza, per stimare δ_a serve un'analisi del grafo computazionale dell'algoritmo che valuta effettivamente $\tilde{f}$).

Con tecniche simili a quanto visto nel caso razionale, si dimostra che (a meno di termini trascurabili di ordine superiore) per l'**errore relativo** vale:

$$\epsilon_f := \frac{f(p_0) - \tilde{f}_a(p_1)}{f(p_0)} \qquad \epsilon_f \approx \epsilon_d + \epsilon_a + \epsilon_{an} \tag{5}$$

dove l'errore relativo analitico è definito come:

$$\epsilon_{an} := \frac{f(p_1) - \tilde{f}(p_1)}{f(p_1)} \tag{6}$$

Stima dell'errore analitico Le quantità δ_{an} ed ϵ_{an} si stimano utilizzando i risultati della **teoria dell'approssimazione**. L'esempio più comune (e l'unico che verrà trattato nel corso) è l'approssimazione di una funzione mediante il **polinomio di Taylor**, per funzioni del tipo $f : \mathbb{R} \to \mathbb{R}$.

Reminder: Data una funzione $f : \mathbb{R} \to \mathbb{R}$, con $f \in C^{n+1}(\mathbb{R})$ e un punto di centro $x_0 \in \mathbb{R}$, allora:

$$f(x) = \underbrace{\sum_{j=0}^{n} \frac{f^{(j)}(x_0)}{j!} \cdot (x - x_0)^j}_{\text{Polinomio di grado } n} + \underbrace{\frac{f^{(n+1)}(\eta)}{(n+1)!}(x - x_0)^{n+1}}_{\text{Resto di Lagrange}} \tag{7}$$

Dove:

- La parte polinomiale sarà la nostra **funzione razionale** $\tilde{f}(x)$ che usiamo per approssimare $f(x)$.
- Il **Resto di Lagrange** è il termine che serve per stimare l'errore analitico.
- η è un valore incognito compreso nell'intervallo tra x e x_0 (ovvero $\eta \in [x, x_0]$ oppure $\eta \in [x_0, x]$).

Osservazione: In questo contesto, l'errore analitico assoluto e relativo si identificano direttamente con il resto della serie di Taylor:

$$\delta_{an}(x) = \frac{f^{(n+1)}(\eta)}{(n+1)!}(x - x_0)^{n+1} \tag{8}$$

$$\epsilon_{an}(x) = \frac{f^{(n+1)}(\eta)}{(n+1)!} \frac{(x - x_0)^{n+1}}{f(x)} \tag{9}$$

Esempio: Approssimazione della Funzione Esponenziale Consideriamo l'approssimazione della funzione $f(x) = e^x$ mediante il suo polinomio di Taylor di grado $n = 2$

centrato in $x_0 = 0$:

$$\tilde{f}(x) = 1 + x + \frac{x^2}{2}$$

Vogliamo stimare quanto sia grande l'errore relativo analitico $|\epsilon_{an}|$ e trovare una sua maggiorazione per $x \in [-1, 1]$.

Calcolo dell'errore analitico assoluto: Utilizzando il resto di Lagrange con $n = 2$ (dove la derivata terza di e^x è ancora e^x):

$$\delta_{an}(x) = e^x - \left(1 + x + \frac{x^2}{2}\right) = \frac{f^{(3)}(\eta)}{3!}x^3 = \frac{e^\eta x^3}{6}$$

con η compreso tra 0 e x.

Calcolo dell'errore analitico relativo: Dividendo per il valore esatto della funzione $f(x) = e^x$:

$$\epsilon_{an}(x) = \frac{\delta_{an}(x)}{f(x)} = \frac{e^\eta x^3}{6e^x}$$

Maggiorazione dell'errore nell'intervallo $[-1, 1]$: Per trovare un limite superiore, cerchiamo i valori massimi dei componenti per $x, \eta \in [-1, 1]$:

$$\max_{x\in[-1,1]} |\epsilon_{an}(x)| \leqslant \max_{\eta\in[-1,1]} e^\eta \cdot \max_{x\in[-1,1]} \left|\frac{x^3}{6e^x}\right| \leqslant \frac{e}{6} \cdot \frac{\max_{x\in[-1,1]} |x^3|}{\min_{x\in[-1,1]} e^x}$$

Sostituendo i valori estremi nel dominio:

$$|\epsilon_{an}(x)| \leqslant \frac{e}{6} \cdot \frac{1}{e^{-1}} = \frac{e^2}{6} \approx 1.23$$

Conclusione: L'errore ottenuto ($\approx 123\%$) non è molto accurato. Questo indica che un polinomio di secondo grado non è sufficiente per approssimare bene l'esponenziale su un intervallo ampio come $[-1, 1]$.

Generalizzazione al Grado n Se considerassimo il polinomio di Taylor di grado n, otterremmo un errore assoluto analitico espresso come:

$$\delta_{an}(x) = \frac{e^\eta x^{n+1}}{(n+1)!} \tag{10}$$

Ragionando come nel caso precedente per la maggiorazione dell'errore relativo nell'intervallo $x \in [-1, 1]$, si ottiene:

$$|\epsilon_{an}(x)| \leqslant \frac{e^2}{(n+1)!} \xrightarrow[n \to +\infty]{} 0 \tag{11}$$

Questo limite ci conferma che all'aumentare del grado del polinomio, l'approssimazione diventa sempre più precisa, tendendo a zero.

Esempio con $n = 4$ Considerando il polinomio di quarto grado:

$$\tilde{f}(x) = 1 + x + \frac{x^2}{2} + \frac{x^3}{6} + \frac{x^4}{24}$$

Per $x \in [-1, 1]$, si ottiene una stima dell'errore molto più contenuta:

$$|\epsilon_{an}(x)| \leqslant \frac{e^2}{5!} = \frac{e^2}{120} \approx 0,061 \tag{12}$$

Conclusione finale: Passando dal grado $n = 2$ al grado $n = 4$, l'errore relativo è sceso da circa $1,23$ (123%) a $0,061$ ($6,1\%$). Questo rende l'approssimazione decisamente più accettabile per fini computazionali.

2 Richiami di Algebra Lineare

L'oggetto di interesse è spesso un vettore $x \in \mathbb{R}^n$, oppure si considerano funzioni $f : \mathbb{R}^n \to \mathbb{R}^m$.

Una funzione $f : \mathbb{R}^n \to \mathbb{R}^m$ si dice lineare se soddisfa le seguenti proprietà:

$$\begin{aligned} f(x+y) &= f(x) + f(y) \quad \forall x, y \in \mathbb{R}^n \\ f(\lambda x) &= \lambda f(x) \quad \forall \lambda \in \mathbb{R},\ \forall x \in \mathbb{R}^n \end{aligned}$$

allora $\exists! A \in \mathbb{R}^{m \times n}$ tale per cui $\forall x \in \mathbb{R}^n$ vale $f(x) = A \cdot x$

$$A = \begin{bmatrix} a_{11} & a_{12} & a_{13} & \dots & a_{1n} \\ a_{21} & a_{22} & a_{23} & \dots & a_{2n} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & a_{n3} & \dots & a_{nn} \end{bmatrix}$$

- Se $m = n \to$ La matrice è **Quadrata**
- Se $m \neq n \to$ La matrice è **Rettangolare**

Definizione

$x_1, ..., x_s \in \mathbb{C}^n$ si dicono linearmente indipendenti se:

$$\sum_{i=1}^{s} \alpha_i \cdot x_i = 0 \iff \alpha_1 = \alpha_2 = \cdots = \alpha_s = 0$$

Viceversa $x_1, \ldots, x_s$ si dicono linearmente dipendenti se $\exists j \in \{1, \ldots, s\}$ tale per cui:

$$x_j = \sum_{i \neq j} \alpha_i x_i \quad \text{per qualche } \alpha_i \in \mathbb{C}$$

Definizione

Un insieme di n vettori linearmente indipendenti in $\mathbb{C}^n$ si dice **base**.

Definizione

Dati $x, y \in \mathbb{C}^n$, si definisce **prodotto scalare** la quantità:

$$\langle x, y \rangle = \sum_{i=1}^{n} x_i \overline{y}_i$$

Di conseguenza, si ha:

$$\langle x, x \rangle = \|x\|_2^2 = \sum_{i=1}^{n} |x_i|^2$$

Definizione

Due vettori x, y si dicono **ortogonali** se vale:

$$\langle x, y \rangle = 0$$

Osservazione: Se contiamo le operazioni di un prodotto scalare, queste sono n prodotti e $n-1$ somme e scriviamo che il suo costo è $\mathcal{O}(n)$ oppure $\mathcal{O}(2n)$. Significa che:

$$\lim_{n \to +\infty} \frac{\text{costo prodotto scalare}}{n} = \text{costante finita} \neq 0$$

Definizione (Trasposta e Trasposta Coniugata)

Sia $A \in \mathbb{C}^{n \times m}$. Si definiscono:

- **Trasposta**: $A^T \in \mathbb{C}^{m \times n}$ tale che:

$$(A^T)_{ij} = A_{ji}$$

- **Hermitiana** (trasposta coniugata): $A^H \in \mathbb{C}^{m \times n}$ tale che:

$$(A^H)_{ij} = \overline{A_{ji}}$$

Esempi

1. Matrice reale:

$$A = \begin{bmatrix} 1 & 7 & 8 \\ 4 & 2 & 9 \\ 5 & 6 & 3 \end{bmatrix} \implies A^T = \begin{bmatrix} 1 & 4 & 5 \\ 7 & 2 & 6 \\ 8 & 3 & 3 \end{bmatrix}$$

2. Matrice complessa:

$$A = \begin{bmatrix} 1 & 2 & 3i \\ -i & 1+i & 0 \\ 4 & 0 & 3 \end{bmatrix} \implies A^H = \begin{bmatrix} 1 & i & 4 \\ 2 & 1-i & 0 \\ -3i & 0 & 3 \end{bmatrix}$$

In MATLAB:

- `A'` $\rightsquigarrow A^H$ (operatore trasposta coniugata)
- `A.'` $\rightsquigarrow A^T$ (operatore trasposta semplice)

Per definire una matrice elemento per elemento in MATLAB:

```
A = [ 1 2 3 ; 4 5 6 ];
```

Che corrisponde a:

$$A = \begin{bmatrix} 1 & 2 & 3 \\ 4 & 5 & 6 \end{bmatrix}$$

Definizione (Matrice Diagonale)

Una matrice si dice **diagonale** se ha elementi nulli fuori dalla diagonale principale, ovvero:

$$a_{ij} = 0 \quad \forall i \neq j$$

In MATLAB: Il comando `diag(v)` crea una matrice con elementi uguali a 0 tranne che sulla diagonale principale, dove inserisce gli elementi del vettore `v`.

Definizione (Matrice Triangolare)

Una matrice quadrata si dice **triangolare superiore** (risp. **inferiore**) se ha tutti gli elementi nulli sotto (risp. sopra) la diagonale principale:

- **Triangolare Superiore (U):**

$$U = \begin{bmatrix} u_{11} & \dots & u_{1n} \\ & \ddots & \vdots \\ 0 & & u_{nn} \end{bmatrix}$$

- **Triangolare Inferiore (L):**

$$L = \begin{bmatrix} l_{11} & & 0 \\ \vdots & \ddots & \\ l_{n1} & \dots & l_{nn} \end{bmatrix}$$

In MATLAB: Esistono i comandi `triu` (*triangle upper*) e `tril` (*triangle lower*) che estraggono rispettivamente la parte triangolare superiore o inferiore di una matrice data in input.

Costo Computazionale e Proprietà del Prodotto

Osservazione: Dato che la matrice prodotto $C = A \cdot B$ ha $m \times p$ entrate, e ogni entrata richiede un prodotto scalare tra una riga di A (lunga n) e una colonna di B, il costo del prodotto è:

$$A \cdot B \implies \mathcal{O}(m \cdot n \cdot p)$$

Se consideriamo matrici quadrate di ordine n ($m = n = p$), il costo diventa $\mathcal{O}(n^3)$.

Osservazione (Matrici Sparse o a Blocchi): Può essere utile decomporre le matrici se una delle due ha molti zeri o se è strutturata a blocchi:

$$A = \begin{bmatrix} A_1 \\ \hline A_2 \end{bmatrix} \implies AB = \begin{bmatrix} A_1 B \\ \hline A_2 B \end{bmatrix}, \quad B = [B_1 | \dots | B_n] \implies AB = [AB_1 | \dots | AB_n]$$

Proprietà del Prodotto

- **Non commutatività:** In generale $AB \neq BA$.

- **Associatività:** $(A \cdot B) \cdot C = A \cdot (B \cdot C)$.
- **Distributività:** $(A + B) \cdot C = AC + BC$.

—

Analisi del Costo Computazionale

Osservazione: Anche se la moltiplicazione è associativa, l'ordine con cui si eseguono le operazioni può influenzare drasticamente il costo. Siano $A \in \mathbb{C}^{m \times n}, B \in \mathbb{C}^{n \times p}, C \in \mathbb{C}^{p \times q}$.

1. $(A \cdot B) \cdot C \implies \mathcal{O}(mnp + mpq)$
2. $A \cdot (B \cdot C) \implies \mathcal{O}(npq + mnq)$

Se, ad esempio, $m = 1$ (vettore riga) e $n = p = q$ sono grandi, il primo metodo costa $\mathcal{O}(n^2)$ mentre il secondo $\mathcal{O}(n^3)$

—

Definizione: Determinante

Data una matrice quadrata $A \in \mathbb{C}^{n \times n}$, il determinante si definisce ricorsivamente (Sviluppo di Laplace):

$$\det(A) = \begin{cases} a_{11} & n = 1 \\ \sum_{j=1}^{n} (-1)^{i+j} a_{ij} \det(A_{ij}) & n > 1 \end{cases}$$

dove A_{ij} è la sottomatrice ottenuta cancellando la riga i e la colonna j

In MATLAB: Si usa la funzione `det(A)`

Casi Particolari e Proprietà

- Per matrici **triangolari** o **diagonali**: $\det(A) = \prod_{i=1}^{n} a_{ii}$. In questo caso il costo è solo $\mathcal{O}(n)$
- $\det(A) = \det(A^T)$
- $\det(A^H) = \overline{\det(A)}$
- $\det(\lambda A) = \lambda^n \det(A)$

Una matrice A si dice **singolare** se $\det(A) = 0$

—

Definizione: Rango

Il **rango** di una matrice $A \in \mathbb{C}^{m \times n}$ è definito equivalentemente come:

- Numero di colonne (o righe) linearmente indipendenti.
- Dimensione massima di un minore non nullo (sottomatrice quadrata con det $\neq 0$)
- Dimensione dell'immagine $Im(A) = \{y \in \mathbb{C}^m : \exists x, y = Ax\}$

Teorema di Binet-Cauchy: $\det(A \cdot B) = \det(A) \cdot \det(B)$

—

Definizione: Matrice Inversa

Sia $A \in \mathbb{C}^{n \times n}$ non singolare. Si definisce l'inversa A^{-1} la matrice tale che:

$$A \cdot A^{-1} = A^{-1} \cdot A = I$$

dove $I = \text{diag}(1, \ldots, 1)$ è la matrice identità

Proprietà dell'inversa:

1. A^{-1} esiste $\iff \det(A) \neq 0 \iff \text{rango}(A) = n$
2. $\det(A^{-1}) = \frac{1}{\det(A)}$
3. $(AB)^{-1} = B^{-1}A^{-1}$

In MATLAB: `inv(A)` per l'inversa e `eye(n)` per la matrice identità.

Proprietà dell'Inversa e Classi di Matrici

Proprietà dell'Inversa:

1. A^{-1} esiste $\iff \det(A) \neq 0 \iff$ le righe/colonne di A sono linearmente indipendenti $\iff \text{rank}(A) = n$
2. Per il teorema di Binet-Cauchy, $\det(A \cdot A^{-1}) = \det(I) = 1$, da cui $\det(A^{-1}) = \frac{1}{\det(A)}$
3. $(A \cdot B)^{-1} = B^{-1} \cdot A^{-1}$ (e analogamente per la trasposta $(AB)^T = B^T A^T$ e l'hermitiana $(AB)^H = B^H A^H$)

Definizione: Matrici Speciali ($\mathbb{C}^{n\times n}$)

Una matrice $A \in \mathbb{C}^{n\times n}$ si dice:

- **Hermitiana** se $A = A^H$
- **Unitaria** se $AA^H = A^H A = I$ (ovvero $A^H = A^{-1}$)
- **Normale** se $AA^H = A^H A$

Nota: Le matrici hermitiane e unitarie sono sottoclassi delle matrici normali

Definizione: Caso Reale ($\mathbb{R}^{n\times n}$)

Se $A \in \mathbb{R}^{n\times n}$, le definizioni precedenti diventano:

- **Simmetrica** se $A = A^T$
- **Ortogonale** se $A^T A = AA^T = I$

—

Matrici di Permutazione

Definizione

Una matrice $P \in \mathbb{R}^{n\times n}$ si dice **di permutazione** se è ottenuta dalla matrice identità permutando l'ordine delle righe o delle colonne

Proprietà:

- Ogni matrice di permutazione è ortogonale: $P^T P = PP^T = I$
- **Effetto del prodotto:** Moltiplicare PA scambia le **righe** di A, mentre AP scambia le **colonne** di A

Esempio: Se $P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$ e $A = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 9 \end{bmatrix}$, allora $PA = \begin{bmatrix} 2 & 5 & 8 \\ 3 & 6 & 9 \\ 1 & 4 & 7 \end{bmatrix}$

—

Sistemi Lineari

Un sistema di m equazioni in n incognite si scrive come $Ax = b$, dove $A \in \mathbb{C}^{m\times n}$, $x \in \mathbb{C}^n$ è il vettore delle incognite e $b \in \mathbb{C}^m$ è il termine noto.

Teorema di Rouché-Capelli

Il sistema $Ax = b$ ammette soluzione se e solo se:

$$\text{rank}(A) = \text{rank}(A|b)$$

dove $[A|b]$ è la matrice aumentata ottenuta aggiungendo b come ultima colonna ad A

Unicità della soluzione:

- Se $\text{rank}(A) = n$ (numero incognite), la soluzione è **unica**
- Se $\text{rank}(A) < n$, esistono **infinite soluzioni** che formano uno spazio affine di dimensione $n - \text{rank}(A)$

Casi particolari:

- **Sistema Omogeneo ($b = 0$):** ammette sempre almeno la soluzione nulla $x = 0$.
- **Sistema Sovradeterminato:** $m > n$.
- **Sistema Sottodeterminato:** $m < n$.

—

Esercizio MATLAB: Sviluppo di Laplace

Consegna: Scrivere una funzione `my_det(A)` che calcoli il determinante facendo lo sviluppo di Laplace sulla prima riga:

$$\det(A) = \sum_{j=1}^{n} (-1)^{1+j} a_{1j} \det(A_{1j})$$

Suggerimenti (Hint):

- Definire la funzione in modo **ricorsivo**
- Caso base: se $n = 1$, $\det(A) = a_{11}$
- Per ottenere la sottomatrice A_{1j} in MATLAB, escludere la prima riga e la colonna j usando gli indici: `A(2:n, [1:j-1, j+1:n])`

...

3 Autovalori e Autovettori

Definizione

Siano $A \in \mathbb{C}^{n\times n}$ e $\lambda \in \mathbb{C}$. Si dice che λ è un **autovalore** di A se esiste un vettore non nullo $v \in \mathbb{C}^n, v \neq 0$ tale che:

$$Av = \lambda v \tag{13}$$

Il vettore v associato a λ si dice **autovettore**. La coppia (λ, v) è detta **autocoppia**.

Esistenza degli autovalori: Dalla relazione $Av = \lambda v$ segue che $(A - \lambda I)v = 0$. Poiché per definizione $v \neq 0$, il sistema lineare omogeneo associato deve ammettere soluzioni non banali. Per il teorema di Cramer, ciò accade se e solo se la matrice $(A - \lambda I)$ è singolare:

$$p_A(\lambda) = \det(A - \lambda I) = 0 \quad \rightsquigarrow \quad \textbf{Equazione Caratteristica}$$

Esempio: Sia $A = \begin{bmatrix} 1 & 3 \\ 0 & 4 \end{bmatrix}$. Calcoliamo il polinomio caratteristico:

$$A - \lambda I = \begin{bmatrix} 1-\lambda & 3 \\ 0 & 4-\lambda \end{bmatrix} \implies \det(A - \lambda I) = (1-\lambda)(4-\lambda) = \lambda^2 - 5\lambda + 4$$

Le radici $\lambda_1 = 1$ e $\lambda_2 = 4$ sono gli autovalori di A.

In generale, $p_A(\lambda)$ è un **polinomio di grado** n in λ. Per il Teorema Fondamentale dell'Algebra, esso ha esattamente n radici complesse (contate con la loro molteplicità). Di conseguenza, ogni matrice quadrata di ordine n possiede esattamente n autovalori.

Definizione: Molteplicità Algebrica

Si definisce **molteplicità algebrica** $\alpha(\lambda_i)$ di un autovalore λ_i la sua molteplicità come radice del polinomio caratteristico $p_A(\lambda)$.

Proprietà degli Autovalori: Se $\lambda_1, \ldots, \lambda_n$ sono gli autovalori di A (ripetuti secondo la loro molteplicità), valgono le seguenti relazioni fondamentali:

- **Traccia:** $\gamma_1 = \mathrm{tr}(A) = \sum_{j=1}^n a_{jj} = \sum_{j=1}^n \lambda_j$
- **Determinante:** $\gamma_n = \det(A) = \prod_{j=1}^n \lambda_j$

Osservazione: Una matrice è singolare ($\det(A) = 0$) se e solo se ammette almeno un autovalore nullo.

3.1 Autospazi e Molteplicità Geometrica

Se v è un autovettore associato a λ, allora anche ogni suo multiplo θv (con $\theta \in \mathbb{C} \setminus \{0\}$) soddisfa l'equazione $A(\theta v) = \lambda(\theta v)$. L'insieme di tutti gli autovettori associati a λ, unitamente al vettore nullo, costituisce un sottospazio vettoriale di $\mathbb{C}^n$.

Definizione: Molteplicità Geometrica

Si definisce **autospazio** relativo a λ il sottospazio:

$$V_\lambda = \ker(A - \lambda I)$$

La sua dimensione è detta **molteplicità geometrica** $\gamma(\lambda)$:

$$\gamma(\lambda) := \dim(\ker(A - \lambda I)) = n - \operatorname{rank}(A - \lambda I) \tag{14}$$

Proprietà delle molteplicità: Per ogni autovalore λ di una matrice A, sussiste sempre la seguente catena di disuguaglianze:

$$1 \leq \gamma(\lambda) \leq \alpha(\lambda) \leq n \tag{15}$$

Se per un autovalore si ha $\gamma(\lambda) < \alpha(\lambda)$, la matrice si dice **difettiva**. Se invece $\gamma(\lambda) = \alpha(\lambda)$ per tutti gli autovalori, la matrice è **diagonalizzabile**.

4 Similitudine tra Matrici

Definizione: Matrici Simili

Due matrici $A, B \in \mathbb{C}^{n \times n}$ si dicono **simili** (e si indica con $A \sim B$) se esiste una matrice non singolare $S \in \mathbb{C}^{n \times n}$ ($\det(S) \neq 0$) tale che:

$$B = S^{-1} A S \tag{16}$$

Teorema: Se $A \sim B$, allora A e B hanno lo **stesso polinomio caratteristico** (e quindi gli stessi autovalori con le stesse molteplicità algebriche). Inoltre, se v è un autovettore di A associato all'autovalore λ, allora $w = S^{-1} v$ è un autovettore di B associato allo stesso λ.

Dimostrazione (Invarianza del Polinomio Caratteristico): Sfruttando le proprietà del determinante e l'identità $I = S^{-1}S$:

$$\begin{aligned}\det(B - \lambda I) &= \det(S^{-1}AS - \lambda I) \\ &= \det(S^{-1}AS - \lambda S^{-1}S) \\ &= \det(S^{-1}(A - \lambda I)S)\end{aligned}$$

Per il teorema di Binet:

$$\begin{aligned}&= \det(S^{-1}) \cdot \det(A - \lambda I) \cdot \det(S) \\ &= \frac{1}{\det(S)} \cdot \det(S) \cdot \det(A - \lambda I) \\ &= \det(A - \lambda I)\end{aligned}$$

Poiché i polinomi caratteristici coincidono, le radici (autovalori) sono le stesse.

Trasformazione degli autovettori: Sia (λ, v) un'autocoppia per A, ovvero $Av = \lambda v$. Verifichiamo che $w = S^{-1}v$ sia autovettore per B:

$$Bw = (S^{-1}AS)(S^{-1}v) = S^{-1}A(SS^{-1})v = S^{-1}Av = S^{-1}(\lambda v) = \lambda(S^{-1}v) = \lambda w$$

Questo dimostra che w soddisfa la definizione di autovettore per B con lo stesso autovalore λ.

Osservazione: Diagonalizzabilità

Una matrice A si dice **diagonalizzabile** se è simile a una matrice diagonale D. In tal caso:

$$D = S^{-1}AS \implies A = SDS^{-1}$$

dove D contiene gli autovalori sulla diagonale e S ha come colonne gli autovettori linearmente indipendenti di A.

Dimostrazione (Trasformazione degli autovettori): Sia (λ, v) un'autocoppia per A. Verifichiamo che $S^{-1}v$ sia autovettore per $B = S^{-1}AS$:

$$B(S^{-1}v) = S^{-1}A\underbrace{(S \cdot S^{-1})}_{I}v = S^{-1}\underbrace{(Av)}_{\lambda v} = S^{-1}\lambda v = \lambda(S^{-1}v)$$

Da cui segue che $S^{-1}v$ è autovettore per B associato all'autovalore λ. $\square$

Esempio: Matrice Diagonale

Sia A una matrice diagonale di ordine n:

$$A = \begin{bmatrix} \lambda_1 & & 0 \\ & \ddots & \\ 0 & & \lambda_n \end{bmatrix}$$

Per una matrice in questa forma, gli autovalori sono esattamente gli elementi λ_i sulla diagonale. Gli autovettori associati sono i vettori della **base canonica** e_i.

Prendendo ad esempio il primo vettore della base canonica e_1:

$$A \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \begin{bmatrix} \lambda_1 \\ 0 \\ \vdots \\ 0 \end{bmatrix} = \lambda_1 \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

In generale, per ogni $i = 1, \ldots, n$, vale la relazione:

$$Ae_i = \lambda_i e_i \tag{17}$$

5 Diagonalizzabilità

Definizione: Matrice Diagonalizzabile

Una matrice $A \in \mathbb{C}^{n \times n}$ si dice **diagonalizzabile** se è simile a una matrice diagonale, ovvero se esiste una matrice non singolare $S \in \mathbb{C}^{n \times n}$ ($\det(S) \neq 0$) tale che:

$$S^{-1}AS = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} = \operatorname{diag}(\lambda_1, \ldots, \lambda_n) \tag{18}$$

Osservazione: In virtù di quanto enunciato nel teorema sulla similitudine:

- Gli elementi diagonali della matrice $S^{-1}AS$ sono esattamente gli **autovalori** di A.
- Le colonne della matrice $S = [v_1 \mid v_2 \mid \cdots \mid v_n]$ sono gli **autovettori** di A, dove ogni v_i è l'autovettore associato all'autovalore λ_i.

Osservazione (Matrici non diagonalizzabili): Non tutte le matrici quadrate sono diagonalizzabili. Una condizione necessaria e sufficiente per la diagonalizzabilità è che, per ogni autovalore λ, la molteplicità algebrica sia uguale a quella geometrica ($\alpha(\lambda) = \gamma(\lambda)$).

Esempio: Un classico esempio di matrice **non** diagonalizzabile è il blocco di Jordan di ordine superiore a 1:

$$J_\lambda = \begin{bmatrix} \lambda & 1 & & 0 \\ & \lambda & \ddots & \\ & & \ddots & 1 \\ 0 & & & \lambda \end{bmatrix}$$

Questa matrice ha un solo autovalore λ con $\alpha(\lambda) = n$, ma $\gamma(\lambda) = 1$. Poiché le molteplicità non coincidono, la matrice non può essere portata in forma diagonale.

Teorema: Condizione Necessaria e Sufficiente

Una matrice $A \in \mathbb{C}^{n\times n}$ è **diagonalizzabile** se e solo se per ogni suo autovalore λ la molteplicità algebrica coincide con la molteplicità geometrica:

$$\alpha(\lambda) = \gamma(\lambda) \quad \forall \lambda \in \sigma(A) \tag{19}$$

Esempio (Blocco di Jordan): Consideriamo la matrice A (un blocco di Jordan di ordine 4 relativo a $\lambda = 1$):

$$A = \begin{bmatrix} 1 & 1 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 0 & 1 & 1 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$

Il polinomio caratteristico è $p_A(\lambda) = \det(A - \lambda I) = (1-\lambda)^4$. L'unico autovalore è dunque $\lambda = 1$ con **molteplicità algebrica** $\alpha(1) = 4$.

Per calcolare la **molteplicità geometrica** $\gamma(1)$, analizziamo il rango di $(A - I)$:

$$\operatorname{rank}(A - I) = \operatorname{rank} \begin{pmatrix} 0 & 1 & 0 & 0 \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \\ 0 & 0 & 0 & 0 \end{pmatrix} = 3$$

Dalla formula per la molteplicità geometrica sappiamo che:

$$\gamma(1) = n - \operatorname{rank}(A - I) = 4 - 3 = 1$$

Poiché $\alpha(1) = 4$ e $\gamma(1) = 1$, si ha $\alpha(1) \neq \gamma(1)$. L'autospazio ha dimensione insufficiente per "coprire" la molteplicità dell'autovalore: la matrice **non è diagonalizzabile**.

Condizione Sufficiente per la Diagonalizzabilità: Se una matrice $A \in \mathbb{C}^{n\times n}$ ha n autovalori **distinti**, allora necessariamente si ha $\alpha(\lambda_i) = \gamma(\lambda_i) = 1$ per ogni $i = 1, \dots, n$. In questo caso, la matrice è sempre **diagonalizzabile**.

Interpretazione Geometrica

Dire che una matrice è diagonalizzabile significa che è possibile scegliere un insieme di autovettori $\{v_1, \dots, v_n\}$ che costituiscono una **base** di $\mathbb{C}^n$.
Di conseguenza, ogni vettore $x \in \mathbb{C}^n$ può essere scritto in modo unico come combinazione lineare degli autovettori:

$$x = \sum_{i=1}^{n} c_i v_i, \quad c_i \in \mathbb{C} \tag{20}$$

Caso Particolare (Ortogonalità): In alcuni casi specifici (molto comuni nel calcolo numerico), è possibile scegliere una base di autovettori che siano non solo linearmente indipendenti, ma anche **ortogonali** (o meglio, **ortonormali**) fra di loro.

Ciò accade se e solo se la matrice è **normale** ($AA^H = A^H A$), il che include le matrici Hermitiane, Simmetriche e Unitarie. In questo scenario la matrice di passaggio S è una matrice unitaria ($S^H = S^{-1}$), il che garantisce una stabilità numerica eccezionale.

6 Il Teorema Spettrale

Teorema Spettrale

Sia $A \in \mathbb{C}^{n\times n}$ una matrice Hermitiana ($A = A^H$). Allora:

1. A è sempre **diagonalizzabile**.
2. Tutti i suoi autovalori $\lambda_1, \dots, \lambda_n$ sono **reali**.
3. Esiste una base di autovettori $\{v_1, \dots, v_n\}$ **ortonormale**, ovvero tale che:

$$v_i^H v_j = \delta_{ij} = \begin{cases} 0 & i \neq j \\ 1 & i = j \end{cases} \tag{21}$$

In forma matriciale: Sia $S = [v_1 \mid v_2 \mid \cdots \mid v_n]$ la matrice che ha per colonne gli autovettori ortonormali. Poiché le colonne sono ortonormali, si ha $S^H S = I$, ovvero S è

una **matrice unitaria** ($S^{-1} = S^H$). La scomposizione spettrale si scrive quindi come:

$$S^H A S = \begin{bmatrix} \lambda_1 & & \\ & \ddots & \\ & & \lambda_n \end{bmatrix} \implies A = SDS^H \tag{22}$$

Significato numerico: In analisi numerica, il teorema spettrale è fondamentale perché le matrici unitarie (o ortogonali nel caso reale) preservano la norma dei vettori e non amplificano gli errori di arrotondamento. Lavorare con matrici Hermitiane garantisce algoritmi molto più stabili e veloci (come il metodo dei gradienti coniugati o la decomposizione QR).

7 Proprietà di Autovalori e Autovettori

1. Traslazione (Shift): Sia (λ, v) un'autocoppia per A. Allora $(\lambda + \delta, v)$ è un'autocoppia per la matrice $A + \delta I$, con $\delta \in \mathbb{C}$.

Dimostrazione: Sfruttando la linearità del prodotto matrice-vettore:

$$(A + \delta I)v = Av + \delta I v = \underbrace{Av}_{\lambda v} + \delta v = \lambda v + \delta v = (\lambda + \delta)v \quad \square$$

2. Elevamento a potenza: Sia (λ, v) un'autocoppia per A. Allora (λ^k, v) è un'autocoppia per la matrice A^k, per ogni $k \in \mathbb{N}$.

Dimostrazione: Procediamo per induzione o applicando ripetutamente la definizione:

$$\begin{aligned} A^k v &= A^{k-1} \cdot (Av) = \lambda A^{k-1} v \\ &= \lambda A^{k-2} \cdot (Av) = \lambda^2 A^{k-2} v \\ &= \dots \\ &= \lambda^k v \quad \square \end{aligned}$$

3. Polinomio di una matrice: Sia $p(x) = \sum_{j=0}^{d} p_j x^j$ un polinomio di grado d. Possiamo definire la matrice $p(A) \in \mathbb{C}^{n \times n}$ come:

$$p(A) = \sum_{j=0}^{d} p_j A^j = p_0 I + p_1 A + \dots + p_d A^d \tag{23}$$

Se (λ, v) è un'autocoppia per A, allora $(p(\lambda), v)$ è un'autocoppia per $p(A)$.

4. Matrice Inversa: Sia A una matrice invertibile ($\det(A) \neq 0$). Se (λ, v) è un'autocoppia per A, allora (λ^{-1}, v) è un'autocoppia per la matrice inversa A^{-1}.

Dimostrazione: Partendo dalla definizione di autocoppia e moltiplicando a sinistra per A^{-1}:

$$\begin{aligned} Av = \lambda v &\implies A^{-1}Av = \lambda A^{-1}v \\ &\implies v = \lambda A^{-1}v \end{aligned}$$

Poiché $\lambda \neq 0$ (essendo A invertibile), possiamo dividere per λ:

$$\implies \lambda^{-1}v = A^{-1}v \quad \square$$

5. Autovalori vs Similitudine: Il fatto che due matrici A e B abbiano gli stessi autovalori **non implica** necessariamente che siano simili:

$$\sigma(A) = \sigma(B) \not\Rightarrow A \sim B$$

Condizione necessaria e sufficiente affinché due matrici siano simili è che esse abbiano la stessa **forma canonica di Jordan** (ovvero la stessa struttura di blocchi e la stessa molteplicità geometrica per ogni autovalore).

6. Matrici Reali e Autovalori Complessi: Sia $A \in \mathbb{R}^{n\times n}$ una matrice a coefficienti reali. Se $\lambda \in \mathbb{C}$ è un autovalore di A, allora anche il suo complesso coniugato $\bar{\lambda}$ è un autovalore di A.

$$\lambda \in \sigma(A) \implies \bar{\lambda} \in \sigma(A) \tag{24}$$

Gli autovalori complessi di una matrice reale si presentano quindi sempre in **coppie coniugate**.

Dimostrazione (Autovalori complessi di matrici reali): Sia $A \in \mathbb{R}^{n\times n}$. Il suo polinomio caratteristico è:

$$p_A(\lambda) = \det(A - \lambda I) = (-1)^n\lambda^n + (-1)^{n-1}\gamma_1\lambda^{n-1} + \cdots + \gamma_n$$

Poiché A è una matrice reale, i coefficienti γ_i (che sono somme di prodotti di elementi di A) sono tutti **reali** ($\gamma_i \in \mathbb{R}$).

Se $\lambda \in \mathbb{C} \setminus \mathbb{R}$ è un autovalore, allora $p_A(\lambda) = 0$. Prendendo il complesso coniugato dell'intera equazione:

$$\begin{aligned} 0 = \overline{p_A(\lambda)} &= \overline{(-1)^n\lambda^n + (-1)^{n-1}\gamma_1\lambda^{n-1} + \cdots + \gamma_n} \\ &= (-1)^n\overline{\lambda}^n + (-1)^{n-1}\overline{\gamma_1}\overline{\lambda}^{n-1} + \cdots + \overline{\gamma_n} \end{aligned}$$

Dato che γ_i sono reali, $\overline{\gamma_i} = \gamma_i$:

$$= (-1)^n \overline{\lambda}^n + (-1)^{n-1} \gamma_1 \overline{\lambda}^{n-1} + \cdots + \gamma_n = p_A(\overline{\lambda})$$

Dunque $p_A(\overline{\lambda}) = 0$, il che dimostra che $\overline{\lambda}$ è un autovalore di A. $\square$

Definizione: Raggio Spettrale

Sia $\lambda_1, \ldots, \lambda_n$ l'insieme degli autovalori di una matrice $A \in \mathbb{C}^{n \times n}$. Si definisce **raggio spettrale** di A la quantità:

$$\rho(A) = \max_{i=1,\ldots,n} |\lambda_i| \tag{25}$$

ovvero il massimo tra i moduli degli autovalori.

Proprietà: Convergenza delle Matrici

Sia $A \in \mathbb{C}^{n \times n}$. La matrice A si dice **convergente a zero** se e solo se il suo raggio spettrale è strettamente minore di 1:

$$\rho(A) < 1 \iff \lim_{k \to +\infty} A^k = 0 \tag{26}$$

Dove con 0 si intende la matrice nulla.

Perché è fondamentale? Questa equivalenza è il pilastro su cui si regge l'analisi dei **metodi iterativi** per la risoluzione di sistemi lineari (come Jacobi o Gauss-Seidel). Se riusciamo a scrivere un algoritmo nella forma $x^{(k+1)} = Bx^{(k)} + c$, l'errore al passo k dipenderà dalla potenza B^k. Grazie a questo teorema, sappiamo che l'errore svanirà se e solo se $\rho(B) < 1$.

Altre Norme Vettoriali comuni: Oltre alla norma euclidea, si definiscono spesso le seguenti norme per un vettore $x \in \mathbb{C}^n$:

- **Norma 1 (Norma della somma):** Somma semplicemente i moduli delle componenti del vettore.
$$\|x\|_1 = \sum_{i=1}^{n} |x_i| \tag{27}$$
- **Norma p (p-norma):** È la generalizzazione della norma euclidea per un intero $p \in \mathbb{N}$:
$$\|x\|_p = \left(\sum_{i=1}^{n} |x_i|^p \right)^{\frac{1}{p}} \tag{28}$$

- **Norma ∞ (Norma del massimo):** Rappresenta il modulo della componente più grande (in valore assoluto). È il limite della norma p per $p \to \infty$:

$$\|x\|_\infty = \max_{i=1,\dots,n} |x_i| \tag{29}$$

Osservazione (Geometria delle norme in $\mathbb{R}^2$): L'insieme dei vettori di norma unitaria ($\|x\| = 1$) cambia radicalmente geometria a seconda della norma scelta. Questo insieme è detto **palla unitaria**.

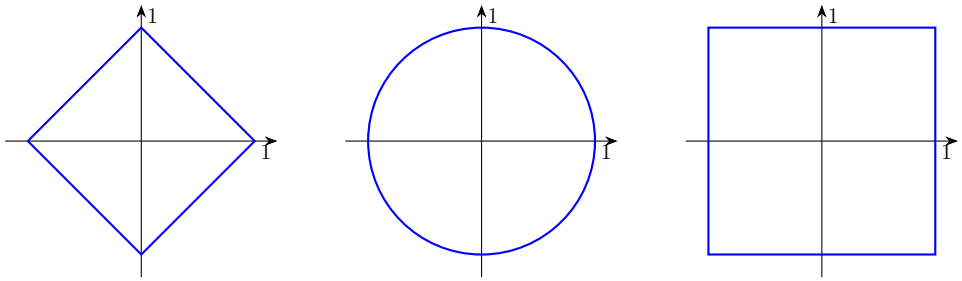

$\|x\|_1 = 1$ $\|x\|_2 = 1$ $\|x\|_\infty = 1$

- **Norma 1:** La palla è un rombo. La distanza è calcolata come somma dei cateti (distanza "Manhattan").
- **Norma 2:** La palla è un cerchio perfetto. È la distanza euclidea "in linea d'aria".
- **Norma ∞:** La palla è un quadrato. La distanza è determinata unicamente dalla componente più grande.

7.1 Equivalenza tra Norme

Definizione: Norme Equivalenti

Due norme $\|\cdot\|_r$ e $\|\cdot\|_q$ su $\mathbb{C}^n$ si dicono **equivalenti** se esistono due costanti reali positive $\alpha, \beta \in \mathbb{R}^+$ tali che:

$$\alpha\|x\|_r \leq \|x\|_q \leq \beta\|x\|_r, \quad \forall x \in \mathbb{C}^n \tag{30}$$

Osservazione: Se vale la relazione sopra riportata, allora è possibile invertire le disuguaglianze per stimare la norma r tramite la norma q:

$$\beta^{-1}\|x\|_q \leq \|x\|_r \leq \alpha^{-1}\|x\|_q$$

Questa proprietà è di fondamentale importanza perché implica che, in uno spazio a dimensione finita, la convergenza di una successione di vettori non dipende dalla norma scelta.

Relazioni tra le norme più comuni: Per le norme vettoriali viste in precedenza $(1, 2, \infty)$, valgono le seguenti catene di disuguaglianze:

- $\|x\|_\infty \leq \|x\|_1 \leq n\|x\|_\infty$
- $\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n}\|x\|_\infty$
- $\|x\|_2 \leq \|x\|_1 \leq \sqrt{n}\|x\|_2$ (**Disuguaglianza di Cauchy-Schwarz**)

Esempio di verifica: $\|x\|_2 \leq \|x\|_1$ in $\mathbb{R}^2$

Consideriamo un vettore $x = (a, b) \in \mathbb{R}^2$. Vogliamo verificare se:

$$\sqrt{a^2 + b^2} \leq |a| + |b|$$

Elevando al quadrato entrambi i membri (essendo entrambi non negativi):

$$\begin{aligned} (\sqrt{a^2 + b^2})^2 &\leq (|a| + |b|)^2 \\ a^2 + b^2 &\leq a^2 + b^2 + 2|ab| \end{aligned}$$

Sottraendo $a^2 + b^2$ da entrambi i lati, otteniamo $0 \leq 2|ab|$, che è sempre vera. Questo conferma che la norma euclidea è sempre minore o uguale alla norma 1.

8 Norme Matriciali

Così come abbiamo definito una misura della "lunghezza" per i vettori, è possibile definire in modo analogo una funzione che misuri la "grandezza" di una matrice.

Definizione: Norma Matriciale

Si definisce **norma matriciale** una funzione $\|\cdot\| : \mathbb{C}^{m\times n} \longrightarrow [0, +\infty)$ che soddisfa le seguenti proprietà per ogni coppia di matrici A, B e per ogni scalare $\alpha \in \mathbb{C}$:

(i) **Definitività**: $\|A\| = 0 \iff A = \mathbf{0}$ (matrice nulla);

(ii) **Omogeneità**: $\|\alpha A\| = |\alpha| \cdot \|A\|$;

(iii) **Disuguaglianza triangolare**: $\|A + B\| \leq \|A\| + \|B\|$;

(iv) **Sub-multiplicatività** (per matrici quadrate $m = n$):

$$\|A \cdot B\| \leq \|A\| \cdot \|B\| \tag{31}$$

Convenzione: D'ora in avanti, salvo diversa indicazione, considereremo esclusivamente il caso di matrici quadrate ($m = n$).

Nota sul significato della sub-multiplicatività: La proprietà (iv) è ciò che distingue una norma matriciale da una semplice norma vettoriale applicata agli elementi della matrice pensata come un vettore lungo n^2. Essa garantisce che il processo di moltiplicazione tra matrici non "esploda" in termini di grandezza rispetto alle singole componenti.

8.1 Norme Indotte (o Naturali)

Definizione: Norma Indotta

Sia $\|\cdot\|_v$ una norma vettoriale su $\mathbb{C}^n$. Si dice **norma matriciale indotta** (o naturale) la funzione $\|\cdot\|_m$ definita come:

$$\|A\|_m = \sup_{x \neq 0} \frac{\|Ax\|_v}{\|x\|_v} = \sup_{\|x\|_v = 1} \|Ax\|_v \tag{32}$$

Interpretazione geometrica: La norma indotta rappresenta il massimo fattore di "allungamento" che la trasformazione lineare associata ad A può applicare a un vettore di norma unitaria.

Norme indotte dai casi classici: Nel caso delle norme vettoriali $1, 2$ e ∞, le rispettive norme matriciali indotte assumono espressioni calcolabili direttamente dagli elementi della matrice:

- **Norma 1 (Norma per colonne):** È il massimo della somma dei moduli degli elementi su ogni colonna.
$$\|A\|_1 = \max_{j=1,\dots,n} \sum_{i=1}^{n} |a_{ij}| \tag{33}$$
- **Norma ∞ (Norma per righe):** È il massimo della somma dei moduli degli elementi su ogni riga.
$$\|A\|_\infty = \max_{i=1,\dots,n} \sum_{j=1}^{n} |a_{ij}| \tag{34}$$
- **Norma 2 (Norma spettrale):** Si calcola tramite il raggio spettrale della matrice $A^H A$.
$$\|A\|_2 = \sqrt{\rho(A^H A)} = \sqrt{\max_{\lambda \in \sigma(A^H A)} |\lambda|} \tag{35}$$

Osservazione: Caso delle matrici Hermitiane

Se la matrice A è **Hermitiana** ($A = A^H$), allora la norma 2 coincide semplicemente con il raggio spettrale di A:

$$\|A\|_2 = \rho(A)$$

8.2 Esempio di Norma non Indotta: La Norma di Frobenius

Esistono norme matriciali che soddisfano gli assiomi (compresa la sub-multiplicatività) ma che non sono generate da una norma vettoriale. L'esempio più importante è la **norma di Frobenius** (o norma di Schur):

$$\|A\|_F = \sqrt{\sum_{i,j=1}^{n} |a_{ij}|^2} \tag{36}$$

Osservazione: Norma dell'identità

Si osserva che per la norma di Frobenius:

$$\|I\|_F = \sqrt{\sum_{i=1}^{n} 1^2} = \sqrt{n} \neq 1 \quad (\text{per } n > 1)$$

Al contrario, **ogni norma indotta** verifica necessariamente $\|I\| = 1$. Infatti:

$$\|I\| = \sup_{x \neq 0} \frac{\|I \cdot x\|}{\|x\|} = \sup_{x \neq 0} \frac{\|x\|}{\|x\|} = 1$$

Questo è un metodo rapido per verificare se una norma matriciale data non è una norma indotta.

8.3 Compatibilità tra Norme

Il concetto di compatibilità lega una norma matriciale a una vettoriale, permettendoci di stimare la "grandezza" del vettore trasformato Ax.

Definizione: Norma Compatibile

Una norma matriciale $\|\cdot\|_m$ si dice **compatibile** con una norma vettoriale $\|\cdot\|_v$ se, per ogni matrice A e per ogni vettore x, vale:

$$\|Ax\|_v \leq \|A\|_m \cdot \|x\|_v \tag{37}$$

Nota: Mentre ogni norma indotta è automaticamente compatibile con la norma vettoriale da cui deriva, una norma non indotta (come quella di Frobenius) può essere compa-

tibile con diverse norme vettoriali (ad esempio, la norma di Frobenius è compatibile con la norma euclidea $\|\cdot\|_2$).

Definizione: Norma Matriciale Compatibile

Una norma matriciale $\|\cdot\|_m$ si dice **compatibile** con una norma vettoriale $\|\cdot\|_v$ se si ha che:

$$\|A \cdot x\|_v \leq \|A\|_m \cdot \|x\|_v \quad \forall A \in \mathbb{C}^{n\times n}, \forall x \in \mathbb{C}^n \tag{38}$$

Osservazione: Le **norme indotte** sono sempre compatibili con le rispettive norme vettoriali da cui sono generate. Questo segue direttamente dalla definizione stessa di norma indotta:

$$\frac{\|A \cdot x\|_v}{\|x\|_v} \leq \sup_{x\neq 0} \frac{\|A \cdot x\|_v}{\|x\|_v} \implies \frac{\|A \cdot x\|_v}{\|x\|_v} \leq \|A\|_m$$

Moltiplicando entrambi i membri per $\|x\|_v$ (che è una quantità non negativa), otteniamo la condizione di compatibilità:

$$\|A \cdot x\|_v \leq \|A\|_m \cdot \|x\|_v \tag{39}$$

Nota bene

La compatibilità è la proprietà "chiave" che permette di stimare come l'errore sui dati di input si propaga attraverso una moltiplicazione matrice-vettore. Senza questa disuguaglianza, non potremmo definire il numero di condizionamento di una matrice.

8.4 Relazioni tra $\|A\|$ e Autovalori di A

Esiste un legame profondo tra la grandezza di una matrice (espressa dalla sua norma) e la posizione dei suoi autovalori nel piano complesso.

Teorema: Maggiorazione degli Autovalori

Sia $\|\cdot\|_m$ una norma matriciale compatibile con una norma vettoriale $\|\cdot\|_v$. Allora la norma della matrice è sempre maggiore o uguale al modulo di ogni suo autovalore:

$$\|A\|_m \geq |\lambda| \quad \forall \lambda \in \sigma(A) \tag{40}$$

Dimostrazione: Sia (λ, x) una qualunque autocoppia per la matrice A. Per definizione di autovalore, abbiamo $Ax = \lambda x$, con $x \neq 0$.

Applichiamo la norma vettoriale $\|\cdot\|_v$ a entrambi i membri e sfruttiamo la proprietà di **compatibilità**:

$$\|\lambda x\|_v = \|Ax\|_v \leq \|A\|_m \cdot \|x\|_v$$

Per l'omogeneità della norma vettoriale, sappiamo che $\|\lambda x\|_v = |\lambda| \cdot \|x\|_v$. Sostituendo:

$$|\lambda| \cdot \|x\|_v \leq \|A\|_m \cdot \|x\|_v$$

Poiché x è un autovettore, esso è per definizione non nullo ($x \neq 0$), il che implica $\|x\|_v \neq 0$. Possiamo quindi dividere entrambi i membri per $\|x\|_v$ ottenendo:

$$|\lambda| \leq \|A\|_m \quad \square \tag{41}$$

Corollario Fondamentale

Data la definizione di raggio spettrale $\rho(A) = \max |\lambda_i|$, il teorema appena dimostrato implica che:

$$\|A\|_m \geq \rho(A) \tag{42}$$

Ovvero, il raggio spettrale rappresenta un **limite inferiore** invalicabile per ogni possibile norma matriciale indotta o compatibile.

8.5 Teorema di Hirsch

Il legame tra norma matriciale e autovalori è formalizzato dal seguente teorema, che identifica nel raggio spettrale un limite inferiore universale:

Teorema di Hirsch

Sia $A \in \mathbb{C}^{n \times n}$. Allora, per ogni norma matriciale $\| \cdot \|$, vale la seguente disuguaglianza:

$$\|A\| \geq \rho(A) \tag{43}$$

dove $\rho(A) = \max_{\lambda \in \sigma(A)} |\lambda|$ è il raggio spettrale di A.

Significato Geometrico: Se visualizziamo gli autovalori della matrice A come punti nel piano complesso, il teorema di Hirsch ci assicura che tutti questi punti cadono all'interno (o sul bordo) di un cerchio centrato nell'origine con raggio pari a $\|A\|$.

Dimostrazione (Teorema di Hirsch): Consideriamo una qualunque autocoppia (λ, x) della matrice A, dove $x \in \mathbb{C}^n$ è l'autovettore associato all'autovalore λ ($Ax = \lambda x$, con $x \neq 0$).

Costruiamo una matrice ausiliaria $B \in \mathbb{C}^{n\times n}$ definita per blocchi di colonne, in cui la prima colonna è l'autovettore x e le restanti $n-1$ colonne sono vettori nulli:

$$B = [x \mid 0 \mid \cdots \mid 0] \tag{44}$$

Calcoliamo ora il prodotto $A \cdot B$ sfruttando le regole del prodotto matrice-matrice:

$$\begin{aligned} A \cdot B &= [Ax \mid A \cdot 0 \mid \cdots \mid A \cdot 0] \\ &= [Ax \mid 0 \mid \cdots \mid 0] \end{aligned}$$

Sostituendo la relazione di autovalore $Ax = \lambda x$:

$$\begin{aligned} &= [\lambda x \mid 0 \mid \cdots \mid 0] \\ &= \lambda[x \mid 0 \mid \cdots \mid 0] = \lambda B \end{aligned}$$

Applichiamo ora una qualunque norma matriciale $\|\cdot\|$ a entrambi i membri della relazione $A \cdot B = \lambda B$. Sfruttando la **proprietà (iv)** (sub-multiplicatività) e la **proprietà (ii)** (omogeneità):

$$\|A\| \cdot \|B\| \geq \|A \cdot B\| = \|\lambda B\| = |\lambda| \cdot \|B\| \tag{45}$$

Poiché x è un autovettore, esso è per definizione non nullo ($x \neq 0$). Di conseguenza, la matrice B non è la matrice nulla ($B \neq \mathbf{0}$) e per la proprietà di definitività delle norme si ha $\|B\| \neq 0$.

Possiamo quindi dividere entrambi i membri per $\|B\|$, ottenendo:

$$\|A\| \geq |\lambda| \tag{46}$$

Poiché la disuguaglianza deve valere per ogni autovalore $\lambda \in \sigma(A)$, essa vale in particolare per quello di modulo massimo, ovvero:

$$\|A\| \geq \rho(A) \quad \square \tag{47}$$

8.6 Interpretazione Geometrica e Convergenza

Il Teorema di Hirsch ci fornisce una localizzazione degli autovalori nel piano complesso.

Osservazione Geometrica: Tutti gli autovalori di A si trovano all'interno del cerchio di raggio $\|A\|$ centrato nell'origine del piano di Gauss.

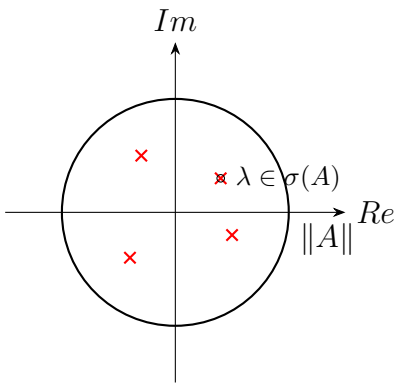

Condizione Sufficiente per la Convergenza: Grazie al teorema di Hirsch, se troviamo **una qualsiasi** norma matriciale tale che $\|A\| < 1$, allora possiamo concludere immediatamente che la matrice è convergente a zero:

$$\|A\| < 1 \implies \rho(A) \leq \|A\| < 1 \implies \lim_{k \to +\infty} A^k = \mathbf{0} \tag{48}$$

ATTENZIONE: Il viceversa non vale

È fondamentale ricordare che la condizione $\|A\| < 1$ è solo **sufficiente**. Non è vero che:

- $\rho(A) < 1 \implies \|A\| < 1$ **(FALSO)**
- $\|A\| > 1 \implies \rho(A) > 1$ **(FALSO)**

Esistono matrici convergenti ($\rho(A) < 1$) che hanno alcune norme molto grandi.

Sintesi del Teorema di Hirsch: Il teorema può essere riassunto come l'appartenenza dello spettro di A al disco chiuso di raggio $\|A\|$:

$$\sigma(A) \subseteq \{z \in \mathbb{C} : |z| \leq \|A\|\} \tag{49}$$

9 Teoremi di Gershgorin

9.1 Definizione e Cerchi di Gershgorin

Sia $A \in \mathbb{C}^{n \times n}$. Definiamo gli insiemi $\mathcal{K}_i(A)$ nel piano complesso come:

$$\mathcal{K}_i(A) = \{z \in \mathbb{C} : |z - a_{ii}| \leq \rho_i\} \tag{50}$$

dove $\rho_i = \sum_{\substack{j=1 \\ j\neq i}}^{n} |a_{ij}|$ rappresenta la somma dei moduli degli elementi extra-diagonali della riga i-esima. L'insieme $\mathcal{K}_i(A)$ è detto **cerchio di Gershgorin** associato alla riga i della matrice A.

Esempio pratico: Se consideriamo una matrice A avente come seconda riga gli elementi $[-i, 1, i]$, il cerchio $\mathcal{K}_2(A)$ associato a tale riga sarà caratterizzato da:

- **Centro:** $a_{22} = 1$.
- **Raggio:** $\rho_2 = |-i| + |i| = 2$.

9.2 1° Teorema di Gershgorin

1° Teorema di Gershgorin

Tutti gli autovalori di una matrice A appartengono all'unione dei suoi cerchi di Gershgorin. Formalmente:

$$\lambda \text{ autovalore di } A \implies \lambda \in \bigcup_{i=1}^{n} \mathcal{K}_i(A) \tag{51}$$

Dimostrazione: Sia (λ, x) un'autocoppia per la matrice A. L'idea della dimostrazione è far vedere che l'autovalore λ appartiene a uno specifico cerchio $\mathcal{K}_k(A)$.

Sia k l'indice per il quale la componente x_k del vettore x ha il modulo massimo, ovvero $|x_k| \geq |x_i|$ per ogni $i = 1, \ldots, n$. Consideriamo la riga k-esima del sistema $Ax = \lambda x$:

$$\sum_{j=1}^{n} a_{kj}x_j = \lambda x_k \implies \sum_{\substack{j=1 \\ j\neq k}}^{n} a_{kj}x_j = (\lambda - a_{kk})x_k$$

Prendendo il valore assoluto di entrambi i membri e applicando la disuguaglianza triangolare, otteniamo:

$$|\lambda - a_{kk}||x_k| = \left| \sum_{\substack{j=1 \\ j\neq k}}^{n} a_{kj}x_j \right| \leq \sum_{\substack{j=1 \\ j\neq k}}^{n} |a_{kj}||x_j|$$

Poiché x è un autovettore, esso non è nullo e quindi possiamo dividere tutto per $|x_k|$:

$$|\lambda - a_{kk}| \leq \sum_{\substack{j=1 \\ j\neq k}}^{n} |a_{kj}| \frac{|x_j|}{|x_k|}$$

Dato che per la nostra scelta iniziale $|x_j|/|x_k| \leq 1$, la disuguaglianza diventa:

$$|\lambda - a_{kk}| \leq \sum_{\substack{j=1 \\ j \neq k}}^{n} |a_{kj}| = \rho_k \implies \lambda \in \mathcal{K}_k(A) \quad \square \tag{52}$$

9.3 Predominanza Diagonale Forte e Invertibilità

Definizione: Predominanza Diagonale Forte

Una matrice $A \in \mathbb{C}^{n \times n}$ si dice a **predominanza diagonale forte** se per ogni sua riga $i = 1, \ldots, n$ vale la disuguaglianza stretta:

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^{n} |a_{ij}| \tag{53}$$

Corollario: Se A è una matrice a predominanza diagonale forte, allora A è sicuramente **invertibile**.

Dimostrazione: Per via del 1° teorema di Gershgorin, i cerchi $\mathcal{K}_i(A)$ hanno un raggio ρ_i che è rigorosamente minore della distanza del centro $|a_{ii}|$ dal punto 0 (origine del piano complesso). A causa di ciò, lo zero non cade in nessun cerchio di Gershgorin. Non potendo essere un autovalore, consegue che $\det(A) \neq 0$ e la matrice risulta invertibile. $\square$

9.4 2° Teorema di Gershgorin

2° Teorema di Gershgorin

Se un gruppo M_1 formato dall'unione di k cerchi di Gershgorin è completamente disgiunto dal gruppo M_2 formato dall'unione dei restanti $n - k$ cerchi (ossia $M_1 \cap M_2 = \emptyset$), allora M_1 contiene esattamente k autovalori e M_2 contiene esattamente gli altri $n - k$ autovalori.

Proprietà derivanti dal teorema:

- Se una matrice A possiede n cerchi tutti mutuamente disgiunti, allora A possiede n autovalori distinti. Questo implica direttamente che A è **diagonalizzabile**.
- Se una matrice a valori reali $A \in \mathbb{R}^{n \times n}$ possiede un cerchio isolato dagli altri, l'autovalore contenuto in tale cerchio è obbligatoriamente un **numero reale**. Infatti, se l'autovalore fosse complesso, anche il suo complesso coniugato dovrebbe essere un autovalore e cadere nello stesso cerchio, violando il limite imposto dal 2° teorema di Gershgorin per un cerchio singolo isolato.

9.5 Implementazione in MATLAB

Per mettere in pratica e visualizzare i concetti studiati in MATLAB, possiamo utilizzare i seguenti comandi:

Comando `plot`:

- Il comando `plot(X, Y, 'r-o')` serve per tracciare un grafico collegando i vettori delle ascisse e delle ordinate specificati.
- Per generare e mostrare il grafico della funzione $\sin(x)$ nell'intervallo $[-5, 10]$:

```
% Genero un po' di punti fra [-5, 102]
N = linspace(-5, 102, 10000); % 10.000 punti equispaziati
Y = sin(N);                   % Applica la funzione sin(x)
plot(N, Y, 'g');              % Traccia la curva in verde (help plot)
```

Disegnare i cerchi di Gershgorin: Per tracciare una circonferenza di centro (x_0, y_0) e raggio R si sfrutta la parametrizzazione polare $(x_0 + R\cos(t), y_0 + R\sin(t))$ per $t \in [0, 2\pi]$. In MATLAB, il codice corretto è:

```
t = linspace(0, 2*pi, 100);
X = x0 + R * cos(t);
Y = y0 + R * sin(t);
plot(X, Y, 'r');
```

Calcolo vettorializzato dei Centri e dei Raggi: Dato che MATLAB è un linguaggio interpretato, conviene evitare i cicli `for` o `while` (loop) quando possibile, sfruttando il calcolo vettorializzato per massimizzare l'efficienza:

```
% Centri: estratti dalla diagonale di A
C = diag(A);

% Raggi: azzero la diagonale principale di A
B = A - diag(diag(A));

% Prendo la matrice con entrate i valori assoluti di B
C_abs = abs(B);

% Sommo gli elementi sulle righe per ottenere i raggi (dimensione 2)
```

```
R = sum(C_abs, 2);
```

10 Localizzazione degli Autovalori: 1° Teorema di Gershgorin

10.1 Ripasso del 1° Teorema di Gershgorin

Ogni autovalore λ di una matrice A è contenuto nell'unione dei suoi cerchi di Gershgorin $\mathcal{K}_i(A)$. Il cerchio $\mathcal{K}_i(A)$ è definito come l'insieme dei punti $z \in \mathbb{C}$ tali che:

$$\mathcal{K}_i(A) = \left\{ z \in \mathbb{C} : |z - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^{n} |a_{ij}| \right\} \tag{54}$$

10.2 Applicazione alla Matrice Trasposta

Dall'algebra lineare sappiamo che una matrice A e la sua trasposta A^T condividono esattamente gli stessi autovalori. Pertanto, possiamo applicare il Teorema di Gershgorin ad A^T. Questo ci permette di individuare un nuovo insieme di cerchi di Gershgorin:

$$\bigcup_{i=1}^{n} \mathcal{K}_i(A^T)$$

I cerchi per la matrice trasposta, $\mathcal{K}_i(A^T)$, si costruiscono in modo analogo:

$$\mathcal{K}_i(A^T) = \left\{ z \in \mathbb{C} : |z - a_{ii}| \leq \sum_{\substack{j=1 \\ j \neq i}}^{n} |a_{ji}| \right\} \tag{55}$$

Come si può notare, il centro $|a_{ii}|$ rimane invariato, ma la somma viene calcolata lungo le *colonne* anziché lungo le *righe*.

Poiché un autovalore λ di A è anche un autovalore di A^T, λ deve appartenere contemporaneamente all'unione dei cerchi di A e all'unione dei cerchi di A^T:

$$\lambda \in \left[\bigcup_{i=1}^{n} \mathcal{K}_i(A) \right] \cap \left[\bigcup_{i=1}^{n} \mathcal{K}_i(A^T) \right] \tag{56}$$

Questa intersezione fornisce una localizzazione più precisa e restrittiva per gli autovalori rispetto all'uso di un solo insieme di cerchi.

11 2° Teorema di Gershgorin

Il secondo teorema afferma che se un gruppo M_1, composto dall'unione di k cerchi di Gershgorin, è completamente isolato (disgiunto) da un secondo gruppo M_2, formato dall'unione dei restanti $n-k$ cerchi (ossia $M_1 \cap M_2 = \emptyset$), allora:

- L'insieme M_1 contiene esattamente k autovalori.
- L'insieme M_2 contiene esattamente gli altri $n-k$ autovalori.

12 Grafi e Matrici

12.1 Grafo Associato a una Matrice

Data una matrice quadrata $A \in \mathbb{C}^{n\times n}$, possiamo costruirne il **grafo associato** $G(A) = (V, E)$.

- L'insieme dei vertici è $V = \{1, 2, \ldots, n\}$.
- L'insieme degli archi, E, è definito dalla seguente relazione: esiste un arco orientato dal nodo i al nodo j se e solo se l'elemento corrispondente nella matrice è non nullo, ovvero $(i, j) \in E \iff a_{ij} \neq 0$.

Esempio: Se $A = \begin{bmatrix} 1 & 4 & 7 \\ 2 & 5 & 8 \\ 3 & 6 & 3 \end{bmatrix}$, il grafo associato avrà 3 vertici (poiché la matrice è 3×3) e gli archi collegheranno tutti i vertici tra loro, dal momento che nessun elemento è uguale a 0.

12.2 Connessione e Riducibilità

- **Grafo Fortemente Connesso:** Un grafo orientato si dice *fortemente connesso* se per ogni coppia di vertici (i, j) esiste un percorso orientato (una sequenza di archi) che porta dal vertice i al vertice j.
- **Matrice Irriducibile:** Una matrice A è detta *irriducibile* se il suo grafo associato $G(A)$ è fortemente connesso.
- **Matrice Riducibile:** Una matrice quadrata $A \in \mathbb{C}^{n\times n}$ (con $n \geq 2$) è detta *riducibile* se esiste una matrice di permutazione $\Pi \in \mathbb{R}^{n\times n}$ tale che la matrice permutata $B = \Pi A \Pi^T$ assuma una forma triangolare a blocchi:

$$B = \Pi A \Pi^T = \begin{bmatrix} \tilde{A}_{11} & \tilde{A}_{12} \\ 0 & \tilde{A}_{22} \end{bmatrix} \tag{57}$$

dove:

- $\tilde{A}_{11} \in \mathbb{C}^{k\times k}$
- $\tilde{A}_{22} \in \mathbb{C}^{(n-k)\times(n-k)}$
- $\tilde{A}_{12} \in \mathbb{C}^{k\times(n-k)}$

Nota: Analogamente, la matrice può essere portata nella forma $\begin{bmatrix} \hat{A}_{11} & 0 \\ \hat{A}_{21} & \hat{A}_{22} \end{bmatrix}$.

13 Estensioni ai Teoremi di Gershgorin

13.1 3° Teorema di Gershgorin (per matrici irriducibili)

3° Teorema di Gershgorin

Sia $A \in \mathbb{C}^{n\times n}$ una matrice **irriducibile**. Se un autovalore λ cade sul *bordo dell'unione* dei cerchi di Gershgorin, allora λ deve trovarsi sull'intersezione dei bordi di *tutti* i cerchi di Gershgorin.

13.2 Matrici a Predominanza Diagonale Debole

Una matrice $A \in \mathbb{C}^{n\times n}$ si dice a **predominanza diagonale debole** se:

1. Per ogni riga j, $|a_{jj}| \geq \sum_{\substack{i=1 \\ i\neq j}}^{n} |a_{ji}|$.
2. Esiste almeno una riga k per cui valga la disuguaglianza stretta: $|a_{kk}| > \sum_{\substack{i=1 \\ i\neq k}}^{n} |a_{ki}|$.

Corollario: Se una matrice A è irriducibile e a predominanza diagonale debole, allora A è **invertibile** (non singolare).

Dimostrazione (per assurdo): Supponiamo che la matrice A sia singolare, ovvero che $\lambda = 0$ sia un autovalore. Poiché A è a predominanza diagonale debole, lo 0 deve appartenere all'unione dei cerchi di Gershgorin. In particolare, per il 3° teorema di Gershgorin (essendo A irriducibile), lo 0 dovrebbe risiedere sul bordo di tutti i cerchi. Tuttavia, esiste almeno un cerchio $\mathcal{K}_k(A)$ (quello associato alla riga con la disuguaglianza stretta) il cui raggio è strettamente minore della distanza del centro dall'origine ($|a_{kk}| > \rho_k$). Pertanto, lo 0 non può appartenere al bordo di $\mathcal{K}_k(A)$, generando una contraddizione. Di conseguenza, $\lambda = 0$ non può essere un autovalore, e A è invertibile. $\square$

14 Matrici a Blocchi

Spesso risulta conveniente rappresentare una matrice in termini di sotto-matrici (blocchi) anziché di singoli elementi scalari.

Una **matrice a blocchi** si scrive nella forma:

$$A = \begin{bmatrix} A_{11} & \dots & A_{1t} \\ \vdots & & \vdots \\ A_{s1} & \dots & A_{st} \end{bmatrix} \tag{58}$$

dove ogni A_{ij} è una matrice di dimensioni $m_i \times n_j$, con $\sum_{i=1}^{s} m_i = m$ e $\sum_{j=1}^{t} n_j = n$. Nel nostro contesto, ci limiteremo spesso al caso di blocchi quadrati lungo la diagonale ($s = t$ e $m_i = n_i$).

14.1 Matrici Triangolari e Diagonali a Blocchi

- **Triangolare Superiore a Blocchi:** $A = \begin{bmatrix} A_{11} & \dots & A_{1s} \\ 0 & \ddots & \vdots \\ 0 & \dots & A_{ss} \end{bmatrix}$
- **Diagonale a Blocchi:** $A = \begin{bmatrix} A_{11} & 0 \\ 0 & A_{22} \end{bmatrix}$ (con i blocchi diagonali quadrati).

Proprietà:

- Se A è una matrice triangolare a blocchi o diagonale a blocchi, il suo determinante è il prodotto dei determinanti dei blocchi diagonali:

$$\det(A) = \prod_{i=1}^{s} \det(A_{ii}) \tag{59}$$

- Le normali operazioni matriciali (somma $A + B$ e prodotto $A \cdot B$) si estendono alle matrici a blocchi operando sui blocchi stessi come se fossero scalari, a condizione che i blocchi siano compatibili in termini di dimensioni.
  - Esempio di prodotto: $A \cdot B = \begin{bmatrix} A_{11}B_{11} + A_{12}B_{21} & \dots \\ \dots & \dots \end{bmatrix}$
  - Esempio di prodotto matrice-vettore: $\begin{bmatrix} A_{11} & A_{12} \\ A_{21} & A_{22} \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} A_{11}x_1 + A_{12}x_2 \\ A_{21}x_1 + A_{22}x_2 \end{bmatrix}$

15 Risoluzione di Sistemi Lineari con Matrici Riducibili

Supponiamo di voler risolvere il sistema lineare $Ax = b$, con $A \in \mathbb{C}^{n\times n}$ matrice **riducibile**. Questo significa che esiste una matrice di permutazione Π tale che:

$$\Pi A \Pi^T = \begin{bmatrix} \tilde{A}_{11} & \tilde{A}_{12} \\ 0 & \tilde{A}_{22} \end{bmatrix} \tag{60}$$

Possiamo sfruttare questa struttura triangolare a blocchi per risolvere il sistema in modo più efficiente:

1. Moltiplichiamo il sistema a sinistra per Π: $\Pi A x = \Pi b$.
2. Inseriamo l'identità $I = \Pi^T \Pi$: $\Pi A(\Pi^T \Pi)x = \Pi b$.
3. Otteniamo il sistema equivalente: $(\Pi A \Pi^T)(\Pi x) = \Pi b$.
4. Definiamo il vettore permutato delle incognite $y = \Pi x$ e il vettore dei termini noti permutato $c = \Pi b$.
5. Riscriviamo il sistema usando la forma a blocchi:

$$\begin{bmatrix} \tilde{A}_{11} & \tilde{A}_{12} \\ 0 & \tilde{A}_{22} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} \tag{61}$$

Questo si traduce in due sistemi lineari più piccoli (uno per ogni blocco diagonale):

- **Sistema 2:** $\tilde{A}_{22} y_2 = c_2$
- **Sistema 1:** $\tilde{A}_{11} y_1 + \tilde{A}_{12} y_2 = c_1 \implies \tilde{A}_{11} y_1 = c_1 - \tilde{A}_{12} y_2$

Procedura di risoluzione:

1. Si risolve il *Sistema 2* (di dimensione $(n-k) \times (n-k)$) per trovare y_2.
2. Si sostituisce il valore calcolato di y_2 nel *Sistema 1* e si risolve tale sistema (di dimensione $k \times k$) per trovare y_1.
3. Si ricostruisce il vettore soluzione originale ri-permutando il vettore y: $x = \Pi^T y$.

15.1 Vantaggio Computazionale

- L'**approccio standard** (risolvere direttamente $Ax = b$) richiede un costo computazionale dell'ordine di $\mathcal{O}(n^3)$ operazioni.

- Risolvere i due sistemi più piccoli richiede $\mathcal{O}((n-k)^3)$ e $\mathcal{O}(k^3)$ operazioni.
- Il caso più favorevole si verifica quando i blocchi hanno dimensione uguale ($k = n/2$).
- In questo scenario ottimale, il costo scende a $2 \cdot (n/2)^3 = n^3/4$. Rispetto al costo n^3 dell'approccio standard, si ottiene un guadagno (speedup) di un **fattore 4**.

16 Grafi e Matrici Riducibili (Continua)

Ci poniamo ora una domanda fondamentale: *come capisco se una matrice è riducibile guardando il suo grafo?*

Teorema (Riducibilità e Grafi)

Una matrice $A \in \mathbb{C}^{n\times n}$ è **riducibile** se e solo se il suo grafo associato $G(A)$ **non è fortemente connesso**.

Dimostrazione: Un'osservazione preliminare: il grafo $G(\Pi A \Pi^T)$ è esattamente lo stesso grafo $G(A)$, a meno di rinominare i vertici (la permutazione cambia solo l'etichetta dei nodi). Di conseguenza, $G(A)$ è fortemente connesso se e solo se $G(\Pi A \Pi^T)$ è fortemente connesso.

($\Longrightarrow$) Se A è riducibile, allora esiste una permutazione tale che:

$$B = \Pi A \Pi^T = \begin{bmatrix} B_{11} & B_{12} \\ 0 & B_{22} \end{bmatrix}$$

Studiando il grafo $G(B)$, si nota che la presenza del blocco di zeri in basso a sinistra indica che non ci sono archi che vanno dai vertici associati a B_{22} (indici da $k+1$ a n) verso i vertici associati a B_{11} (indici da 1 a k). Pertanto, non è possibile raggiungere la parte superiore del grafo partendo dalla parte inferiore: il grafo non può essere fortemente connesso.

($\Longleftarrow$) Se $G(A)$ non è fortemente connesso, allora esiste almeno una coppia di vertici (i, j) tali che non è possibile raggiungere j partendo da i. Definiamo due insiemi:

$$Q = \{\text{vertici raggiungibili partendo da } i\}$$
$$\bar{Q} = \{\text{vertici NON raggiungibili partendo da } i\}$$

L'insieme Q contiene almeno i, e l'insieme $\bar{Q}$ contiene almeno j, quindi sono entrambi non vuoti ($\neq \emptyset$). Consideriamo una matrice di permutazione Π che metta in testa

gli indici di Q seguiti dagli indici di $\bar{Q}$. Otterremo:

$$\Pi A \Pi^T = \begin{array}{cc} Q & \bar{Q} \\ \begin{bmatrix} * & * \\ 0 & * \end{bmatrix} & \begin{array}{c} Q \\ \bar{Q} \end{array} \end{array}$$

Se per assurdo ci fosse un elemento non nullo nel blocco in basso a sinistra, significherebbe che esiste un arco da un elemento di $\bar{Q}$ a un elemento di Q. Ma per definizione di Q e $\bar{Q}$, questo è impossibile. Dunque, la matrice assume la forma triangolare a blocchi, dimostrando che A è riducibile. $\square$

Esercizio/Esempio Pratico: Sia data la matrice:

$$A = \begin{bmatrix} 3 & 0 & 6 \\ 2 & 4 & 7 \\ 3 & 0 & 0 \end{bmatrix}$$

Scegliamo un nodo da cui partire, ad esempio il nodo 2.

- Vertici raggiungibili da 2: $Q = \{1, 3\}$ (infatti $a_{21} = 2 \neq 0$ e $a_{23} = 7 \neq 0$, e dal nodo 1 vado al nodo 3).
- Vertici NON raggiungibili da 2: $\bar{Q} = \{2\}$. (Non ci sono archi di ritorno al nodo 2).

Costruiamo la permutazione che mette in testa gli elementi di Q seguiti da $\bar{Q}$: l'ordine sarà $(1, 3, 2)$. La matrice di permutazione Π sarà:

$$\Pi = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 0 & 1 \\ 0 & 1 & 0 \end{bmatrix} \implies \Pi A \Pi^T = \begin{bmatrix} 3 & 6 & 0 \\ 3 & 0 & 0 \\ 2 & 7 & 4 \end{bmatrix}$$

Nota: in MATLAB la permutazione si esegue definendo il vettore `p = [1 3 2]` *e calcolando* `B = A(p, p)`.

Riduzione Ricorsiva a Blocchi: Dopo aver portato la matrice nella forma ridotta $\begin{bmatrix} A_{11} & A_{12} \\ 0 & A_{22} \end{bmatrix}$, niente vieta di applicare l'approccio ricorsivamente sui blocchi diagonali A_{11} e A_{22}, se questi sono a loro volta riducibili. Continuando il procedimento fino a quando tutti i blocchi diagonali sono **irriducibili**, la matrice apparirà come una triangolare superiore a blocchi:

$$A_{rid} = \begin{bmatrix} A_{11} & * & \dots & * \\ 0 & A_{22} & \dots & * \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & A_{tt} \end{bmatrix}$$

Il guadagno nel risolvere un sistema lineare $Ax = b$ con questa forma è notevole, poiché si riduce alla risoluzione a cascata (all'indietro) di t sistemi lineari più piccoli corrispondenti ai blocchi A_{ii}.

17 Sistemi Lineari: Metodi Risolutivi

Dato un sistema lineare di n equazioni in n incognite:

$$Ax = b \quad \text{con } A \in \mathbb{C}^{n\times n}, \quad x, b \in \mathbb{C}^n \tag{62}$$

Esistono due famiglie principali di approcci per risolverlo:

1. **Metodi Diretti:** In aritmetica esatta (senza errori di arrotondamento), arrivano alla soluzione del problema con un **numero finito** di operazioni.
2. **Metodi Iterativi:** Generano una successione di vettori $\{x_k\}$ che **converge al limite** alla soluzione vera solo per $k \to +\infty$.

Esempio (Metodo Diretto Inefficiente): Il Metodo di Cramer è un metodo diretto, ma è computazionalmente inaccettabile. Il calcolo dei determinanti costa $\mathcal{O}(n!)$ usando Laplace, o al meglio $\mathcal{O}(n^3)$. Non viene usato nella pratica numerica per n elevato.

17.1 Sistemi Triangolari

I sistemi lineari più facili da risolvere sono quelli triangolari. Supponiamo di avere un sistema triangolare superiore $Ux = c$:

$$\begin{bmatrix} u_{11} & \dots & u_{1n} \\ 0 & \ddots & \vdots \\ 0 & 0 & u_{nn} \end{bmatrix} \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} c_1 \\ \vdots \\ c_n \end{bmatrix}$$

Questo sistema si risolve con il **Metodo della Sostituzione all'Indietro** (Backward Substitution):

$$\begin{cases} x_n = \dfrac{c_n}{u_{nn}} \\ x_i = \dfrac{c_i - \sum_{j=i+1}^{n} u_{ij} x_j}{u_{ii}} \quad \text{per } i = n-1, \dots, 1 \end{cases} \tag{63}$$

Costo Computazionale: Per calcolare ogni incognita x_i sono necessari $(n-i)$ prodotti, $(n-i-1)$ somme, più due operazioni finali (una differenza e un rapporto). Il costo totale si valuta sommando per i che va da 1 a n:

$$\text{Costo} = \sum_{i=1}^{n} [2(n-i)+1] = n^2 \tag{64}$$

Il costo è dell'ordine di $\mathcal{O}(n^2)$ operazioni in virgola mobile (flops). Un risultato identico ($\mathcal{O}(n^2)$) vale per i sistemi triangolari inferiori risolti con la **Sostituzione in Avanti**.

17.2 Metodo di Eliminazione di Gauss (MEG)

L'idea di base dell'eliminazione di Gauss è applicare trasformazioni lineari alle equazioni del sistema $Ax = b$ per arrivare a un **sistema equivalente** (con la stessa soluzione) ma con una matrice dei coefficienti **triangolare superiore** $Ux = c$. A quel punto si applica la sostituzione all'indietro.

Al passo k, si cerca di eliminare l'incognita x_k dalle equazioni successive (dalla riga $k+1$ alla n). Per farlo, si sottrae dalla riga i un multiplo della riga pivot k. I coefficienti per cui si moltiplica la riga sono detti **moltiplicatori**:

$$m_{ik} = \frac{a_{ik}^{(k-1)}}{a_{kk}^{(k-1)}} \quad \text{per } i = k+1, \dots, n \tag{65}$$

Costo Computazionale del MEG:

- Riduzione a forma triangolare (triangolarizzazione): $\mathcal{O}(\frac{2}{3}n^3)$ operazioni.
- Risoluzione del sistema $Ux = c$: $\mathcal{O}(n^2)$ operazioni.

Dato che per n grande il termine cubico domina incontrastato, il costo del sistema è considerato $\mathcal{O}(\frac{2}{3}n^3)$.

Estensione a Matrici di Termini Noti ($AX = B$): Se si deve risolvere un'equazione matriciale $AX = B$ (dove B è una matrice $n \times s$), equivale a risolvere s sistemi lineari con la stessa matrice dei coefficienti A. È sufficiente applicare l'algoritmo di Gauss alla matrice aumentata $[A|B]$ per arrivare a $[U|C]$, e poi risolvere gli s sistemi triangolari $Ux^{(i)} = c^{(i)}$.

Nota sul Pivoting

L'algoritmo standard di Gauss fallisce se il pivot $a_{kk}^{(k-1)}$ è nullo. Inoltre, se il pivot è molto vicino a zero, i moltiplicatori diventano enormi, causando una grave perdita di accuratezza numerica a causa degli errori di arrotondamento. Per evitare questo, si applicano strategie di **Pivoting** (scambio di righe) per portare sulla diagonale l'elemento con modulo massimo.

18 Fattorizzazione LU

L'algoritmo di Gauss può essere interpretato in forma puramente matriciale. Ogni passo di eliminazione corrisponde a pre-moltiplicare il sistema per una matrice elementare (matrice

di Gauss) H_k:

$$H_{n-1}H_{n-2}\dots H_1Ax = H_{n-1}\dots H_1b$$

Questo prodotto di matrici H applicato ad A restituisce la matrice triangolare superiore U:

$$(H_{n-1}\dots H_1)A = U \implies A = (H_1^{-1}\dots H_{n-1}^{-1})U$$

Si può dimostrare che il prodotto delle inverse delle matrici di Gauss forma una matrice **triangolare inferiore** L con elementi pari a 1 sulla diagonale principale e i moltiplicatori di Gauss sotto la diagonale. Otteniamo così la fattorizzazione:

$$A = L \cdot U \tag{66}$$

Risoluzione di $Ax = b$ con la Fattorizzazione LU: Una volta nota la fattorizzazione $A = LU$, risolvere il sistema diventa molto efficiente:

$$LUx = b \implies \begin{cases} Lz = b & \text{(Risolvo per } z \text{ con sostituzione in avanti)} \\ Ux = z & \text{(Risolvo per } x \text{ con sostituzione all'indietro)} \end{cases} \tag{67}$$

Osservazione: Trovare la fattorizzazione LU equivale ad eseguire la prima fase del metodo di Gauss, con un costo di $\mathcal{O}(\frac{2}{3}n^3)$. Una volta che le matrici L e U sono note, risolvere ogni nuovo sistema $Ax = b$ con un termine noto diverso costa solo $\mathcal{O}(n^2)$ (il costo della risoluzione dei due sistemi triangolari).

18.1 Risoluzione di Sistemi Multipli e Calcolo dell'Inversa

L'algoritmo di Gauss può essere utilizzato in modo efficiente per risolvere sistemi lineari multipli aventi la stessa matrice dei coefficienti A, della forma $AX = B$. Se $A \in \mathbb{C}^{n\times n}$ e $B \in \mathbb{C}^{n\times s}$, la matrice incognita X avrà dimensione $n \times s$. Invece di risolvere s sistemi separati, si può applicare l'eliminazione di Gauss direttamente alla matrice aumentata $[A|B]$.

Calcolo dell'Inversa (Metodo di Gauss-Jordan): Un caso particolare fondamentale è la ricerca della matrice inversa A^{-1}. Vogliamo trovare una matrice X tale che $AX = I$, dove I è la matrice identità di ordine n. Questo equivale a risolvere n sistemi lineari in cui le colonne dei termini noti sono le colonne della matrice identità.

Procedura Pratica per l'Inversa

1. Si affianca alla matrice A la matrice identità I, formando la matrice aumentata $[A|I]$.
2. Si applicano le mosse di Gauss per annullare tutti gli elementi sotto la diagonale, ottenendo $[U|C]$.
3. **Due opzioni:**
   - Risolvere all'indietro gli n sistemi triangolari superiori aventi U come matrice dei coefficienti e le colonne di C come termini noti.
   - Continuare con le mosse di Gauss "all'indietro" per azzerare anche gli elementi sopra la diagonale, trasformando il blocco di sinistra in una matrice diagonale, e infine dividere ogni riga per il proprio pivot per ottenere $[I|A^{-1}]$.

19 Il Metodo di Gauss con Pivoting Parziale

In generale, per applicare l'algoritmo di Gauss "standard", la condizione necessaria è che ad ogni passo j l'elemento pivotale sia non nullo ($a_{jj}^{(j-1)} \neq 0$). Se questa condizione non è verificata, l'algoritmo è costretto a fermarsi. Inoltre, anche se il pivot non è esattamente zero ma è molto piccolo, si possono generare problemi gravi dal punto di vista della stabilità numerica (amplificazione degli errori di arrotondamento a causa di moltiplicatori enormi).

Pivoting Parziale (o per Colonne)

Per ovviare a questo problema, ad ogni passo j dell'algoritmo, prima di calcolare i moltiplicatori e azzerare gli elementi, si effettua una ricerca nella parte di colonna al di sotto della diagonale. Si cerca l'indice i (con $i \geq j$) tale che l'elemento sia massimo in modulo:

$$i = \arg\max_{k \geq j} |a_{kj}^{(j-1)}|$$

Una volta trovato, si **scambia la riga j con la riga i**, portando così l'elemento più grande possibile in posizione pivotale (a_{jj}). Successivamente, si esegue il classico passo di Gauss.

19.1 Effetti del Pivoting sulla Fattorizzazione LU

Dal punto di vista matriciale, uno scambio di righe equivale a premoltiplicare la matrice per una matrice di permutazione Π_j. Ad ogni passo avremo quindi una sequenza del tipo:

$$\dots H_2 \Pi_2 H_1 \Pi_1 A$$

È possibile dimostrare che l'effetto complessivo di tutte queste permutazioni può essere compattato in un'unica matrice di permutazione globale P (spesso indicata con Π). La fattorizzazione risultante prende il nome di **Fattorizzazione** $PA = LU$:

$$PA = LU \tag{68}$$

- P: Matrice di permutazione che rappresenta la composizione di tutti gli scambi di righe effettuati.
- U: La matrice triangolare superiore trovata alla fine dell'algoritmo.
- L: Matrice triangolare inferiore con 1 sulla diagonale che contiene i moltiplicatori usati durante i vari passi, ma *scambiati* in base alle permutazioni applicate successivamente.

20 Calcolo del Determinante tramite LU

Una diretta e utilissima conseguenza della fattorizzazione LU riguarda il calcolo del determinante. Sfruttando il Teorema di Binet-Cauchy:

$$\det(A) = \det(L) \cdot \det(U) = \det(U) = \prod_{j=1}^{n} u_{jj} \tag{69}$$

Sapendo che il determinante di L è sempre 1 (poiché ha solo 1 sulla diagonale), il determinante di A si riduce al prodotto degli elementi sulla diagonale della matrice U. Dato che gli elementi diagonali di U sono esattamente i pivot, essi sono noti alla fine dell'esecuzione di Gauss.

Efficienza computazionale: Il costo per ottenere la fattorizzazione LU e moltiplicare i termini diagonali è di $\mathcal{O}(\frac{2}{3}n^3)$ operazioni. Questo approccio è incomparabilmente migliore (e utilizzato nella pratica) rispetto allo sviluppo di Laplace, che ha un costo inaccettabile di $\mathcal{O}(n!)$.

Caso con Pivoting ($PA = LU$): Se l'algoritmo ha richiesto degli scambi di riga, il determinante subisce un cambio di segno ad ogni scambio. Partendo dalla relazione

$\det(P)\det(A) = \det(L)\det(U)$, otteniamo:

$$\det(A) = (-1)^s \det(U) \tag{70}$$

dove s è il numero totale di scambi di riga effettuati durante il pivoting.

21 Condizionamento di un Sistema Lineare

Supponiamo di voler risolvere il sistema lineare $Ax = b$ in un calcolatore. A causa della rappresentazione floating-point o di errori di misura, i dati in input possono subire delle piccole perturbazioni. Ci chiediamo: se perturbiamo il sistema originale di una quantità δA e δb, la soluzione calcolata $x + \delta x$ quanto sarà lontana dalla soluzione esatta x?.

Per isolare il problema, consideriamo solo una perturbazione sul termine noto ($\delta A = 0$):

$$A(x + \delta x) = b + \delta b \tag{71}$$

Sottraendo membro a membro il sistema originale $Ax = b$, otteniamo un'equazione che lega direttamente la perturbazione del termine noto all'errore sulla soluzione:

$$A\delta x = \delta b \implies \delta x = A^{-1}\delta b \tag{72}$$

Passando alle norme vettoriali (e alle norme matriciali compatibili associate), possiamo stimare l'entità dell'errore assoluto:

$$\|\delta x\| \leq \|A^{-1}\| \cdot \|\delta b\|$$

Tuttavia, ciò che interessa maggiormente è l'errore relativo. Partendo dalla relazione $b = Ax$, la compatibilità tra norme garantisce che $\|b\| \leq \|A\| \cdot \|x\|$, che riorganizzata diventa:

$$\|x\| \geq \frac{\|b\|}{\|A\|}$$

Mettendo insieme la maggiorazione per $\|\delta x\|$ e la minorazione per $\|x\|$, si arriva alla stima dell'errore relativo finale:

$$\frac{\|\delta x\|}{\|x\|} \leq \underbrace{\left(\|A\| \cdot \|A^{-1}\|\right)}_{\mu(A)} \cdot \frac{\|\delta b\|}{\|b\|} \tag{73}$$

Numero di Condizionamento

La quantità $\mu(A) := \|A\| \cdot \|A^{-1}\|$ prende il nome di **Numero di Condizionamento** della matrice A (rispetto alla norma scelta).
Per via delle proprietà delle norme sub-moltiplicative e sapendo che $\|I\| \geq 1$ (o $= 1$ per norme indotte), vale sempre la relazione:

$$\mu(A) \geq 1$$

Interpretazione del Condizionamento:

- Se $\mu(A) \approx 1$, l'errore relativo sui dati si trasferisce sulla soluzione senza essere amplificato in modo significativo. Il sistema si dice **ben condizionato**.
- Se $\mu(A) \gg 1$, anche un piccolissimo errore nei termini noti può provocare variazioni abnormi nella soluzione finale. In questo caso il sistema è **mal condizionato**.
- **Regola empirica:** Se il numero di condizionamento è dell'ordine di 10^k, ci si aspetta di perdere fino a k cifre significative di precisione nella soluzione calcolata.